



ONDOKUZ MAYIS ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

MAKİNE ÖĞRENİMİ VE DERİN ÖĞRENME İLE DUYGU ANALİZİ
PROJE RAPORU

ALEYNA KAHRAMAN

DİLARA BIYIKLI

FEYZANUR AYTEKİN

HASAN BASRİ DARGA

Danışman

Dr. Öğr. Üyesi DURMUŞ ÖZKAN ŞAHİN

OCAK, 2024

TEŞEKKÜR

Proje boyunca yardımlarını esirgemeyen ve her konuda bilgisini paylaşan danışman hocamız Doktor Öğretim Üyesi Durmuş Özkan ŞAHİN'e teşekkür ederiz.

Ö Z E T

Duygu analizi, metin, ses veya görüntü verilerindeki duygusal içerikleri anlamak, sınıflandırmak ve çıkarsamak amacıyla kullanılan bir bilgi işleme yöntemidir. Bu teknik, genellikle doğal dil işleme algoritmaları ve makine öğrenimi teknikleri kullanılarak uygulanır. Duygu analizi, metinleri pozitif, negatif veya nötr duygusal kategorilere ayırarak içerdikleri duygusal tonları anlamaya çalışır. Bu analiz yöntemi, bir dizi farklı uygulama alanında etkili bir şekilde kullanılabilir. Örneğin, sosyal medya izleme, marka itibarı yönetimi için müşteri geri bildirimlerini anlama, pazar araştırmaları, halk sağlığı izleme, finansal piyasa analizi ve daha birçok alanda duygu analizi verimli bir araç olarak öne çıkar. Şirketler, müşteri deneyimi üzerinde derinlemesine anlayış elde ederek ürün veya hizmetlerini iyileştirebilir. Pazarlama stratejilerini geliştirebilir, rekabet analizi yapabilir ve tüketici taleplerine daha iyi cevap verebilirler. Duygu analizi aynı zamanda acil durum yönetimi ve kriz iletişimi süreçlerinde de kullanılabilir. Sosyal medya platformları üzerinden halkın duygusal tepkilerini izleyerek salgınlar veya doğal afetler gibi olaylara hızlı bir şekilde yanıt verebilme kabiliyeti sağlar. Bu sayede, toplulukların ihtiyaçlarına daha etkili bir şekilde karşılık verilebilir. Bu çalışmada 39 tane güncel duygu analizi çalışması okunup değerlendirilmiştir. Duygu analizinde sık kullanılan makine öğrenmesi ve doğal dil işleme teknikleri ile ilgili bilgiler verilmiştir. Son olarak bitirme projesi kapsamında gelecek dönem yapılacaklar ile ilgili bilgi verilmiştir.

Anahtar Kelimeler: Makine Öğrenimi, Derin Öğrenme, Duygu Analizi, Naive Bayes, Destek Vektör Makineleri, Sınıflandırma, Metin Temsil

İÇİNDEKİLER

I GİRİŞ

1 Amaç	2
2 LİTERATÜR ÖZETİ	3

II MATERYAL

3 ÇALIŞMADA KULLANILACAK VERİ SETLERİ	32
3.1 IMDB Film Yorumları	33
3.2 Amazon Kullanıcı Yorumları	33
4 KÜTÜPHANELER	35
4.1 NLTK	35
4.2 Zemberek	35
4.3 TensorFlow	36
4.4 Spacy	36
4.5 Numpy	36
4.6 Pandas	37
4.7 Keras	37
4.8 scikit-learn	38
4.9 e1071	38
4.10 Twint	39

III Yöntem

5	VERİLERİN HAZIRLANMASI	41
5.1	Veri Ön işleme	41
5.2	Metin Temsil Yöntemleri	41
5.2.1	Terim Sıklığı-Ters Belge Frekansı (TF-IDF)	42
5.2.2	Kelime Çantası (Bag Of Words)	43
5.2.3	Word2Vec	43
6	SINIFLANDIRMA YÖNTEMLERİ	45
6.1	Naive Bayes (NB)	45
6.2	Destek Vektör Makineleri (SVM)	45
6.3	Lojistik Regresyon (LR)	46
6.4	Karar Ağaçları (DT)	46
6.5	Rastgele Orman (RF)	46
6.6	Derin Öğrenme Modelleri	47
6.6.1	Tekrarlayan Sinir Ağları (RNN)	47
6.6.2	Yapay Sinir Ağları (Artificial Neural Networks - ANN)	47
6.6.3	Evrişimli Sinir Ağları (CNN)	48
6.7	K-En Yakın Komşu (k-NN)	48
7	DEĞERLENDİRME	49
7.1	Doğruluk (Accuracy)	49
7.2	Duyarlılık (Recall)	50
7.3	Hassasiyet (Precision)	50
7.4	F1 Skoru	51
7.5	Süre (Time)	51

IV GELECEK ÇALIŞMALAR

8 GELECEK ÇALIŞMALAR 53

KAYNAKÇA 55

ŞEKİLLER LİSTESİ

1	Veri Setinin Temizlenmesi için Uygulanan Adımlar	42
2	Bag Of Words Yöntemi	43
3	CBOW Modeli	44
4	Skip-gram Modeli	44
5	Projenin iş zaman planlaması	54

ÇİZELGELER LİSTESİ

1	Çalışmaların Karşılaştırılması	28
2	Çalışmaların Karşılaştırılması	29
3	Çalışmaların Karşılaştırılması	30

KISALTMALAR

Türkçe	İngilizce	Kısaltma
Doğal Dil İşleme	Natural Language Processing	NLP
Doğal Dil Araçları Kiti	Natural Language Toolkit	NLTK
Kelime Sıklığı-Ters Belge Frekansı	Term Frequency-Inverse Document Frequency	TF-IDF
Kelimelerin Çantası	Bag of Words	BOW
Naive Bayes	Naive Bayes	NB
Destek Vektör Makinesi	Support Vector Machine	SVM
Destek Vektör Sınıflandırma	Support Vector Classification	SVC
Lojistik Regresyon	Logistic Regression	LR
Karar Ağacı	Decision Tree	DT
Rastgele Orman	Random Forest	RF
Tekrarlayan Sinir Ağı	Recurrent Neural Network	RNN
Yapay Sinir Ağı	Artificial Neural Network	ANN
Evrişimli Sinir Ağı	Convolutional Neural Network	CNN
K-En Yakın Komşu	K-Nearest Neighbors	kNN

BÖLÜM: İ

GİRİŞ

AMAÇ

Duygu analizi, metin, konuşma veya diğer iletişim biçimlerindeki içeriklerin duygusal tonunu belirleme sürecini ifade eder. Temel olarak duygu analizi, metinlerdeki ifadelerin duygusal içeriğini anlamak ve çeşitli duygusal kategorilere ayırmak amacını taşır. Bu yöntem, müşteri geri bildirimlerini değerlendirmek, sosyal medya içeriklerini anlamak, pazar araştırmalarını yönlendirmek gibi birçok uygulama alanında fayda sağlar. İşletmeler müşteri memnuniyetini artırabilir, marka itibarını yönetebilir, sosyal medya etkileşimlerini değerlendirebilir ve pazarlama stratejilerini şekillendirebilir. Aynı zamanda, sağlık sektöründe hastaların duygusal durumlarını izlemek, siyasi analizlerde toplumun duygusal tepkilerini anlamak gibi alanlarda da kullanılarak daha geniş bir anlam taşır. Duygu analizi konusunda yapılan araştırmalar detaylı bir şekilde ele alınacaktır. Araştırmaların sonuçları doğrultusunda kullanılan yöntemlerin analizi yapılarak kendi projemiz için bir yol haritası oluşturmayı planlıyoruz.

LİTERATÜR ÖZETİ

Rawat ve arkadaşları [28] yapmış oldukları çalışmada, aşıyla ilgili atılmış tweetleri kullanarak kamuoyunun aşıyla ilgili duyarlılığını değerlendirmek için duygu analizi yöntemini tercih etmişler. Aşıyla ilgili tweetlerin veri seti kaggle web sitesinden alınmıştır. Özel karakterler, hashtag'ler, noktalama işaretleri, bağlantılar ve satır sonları gibi metnin ilgisiz kısımlarını kaldırmak için Spacy kütüphanesini kullanılmıştır. İlgisiz tüm kelime veya sembollerin kaldırılması için Nexttext kütüphanesi kullanıldı. TF-IDF yöntemini kullanarak işlenmiş tweetler vektörlere dönüştürüldü. Sınıflandırma için Bernoulli Naïve Bayes (BNB), Destek Vektör Sınıflandırıcı (SVC) ve Lojistik Regresyon (LR) kullanıldı. 78771 adet olumlu tweet, 23993 adet olumsuz tweet bulundu. 125443 tweet'in çoğu nötrdür. SVC modeli %97 ile en yüksek doğruluğu sağladı. BNB modelinin doğruluğu %81 iken LR modelinin doğruluğu %95'tir.

Demir ve Bilgin [10] yapmış oldukları çalışmada, türkçe haber metinlerinden elde edilen veriler üzerinde BERT tabanlı dil modelleri ve makine öğrenmesi algoritmaları ile duygu analizi yapmıştır. BERT tabanlı dil modelleri olarak ALBERT, DistilBERT ve RoBERTa, makine öğrenme algoritmaları olarak ise Naive Bayes, Destek Vektör Makinesi ve Rastgele Orman yöntemleri kullanılmıştır. Veri seti 5000 adet olumlu ve olumsuz cümle içermektedir ve verilerin %90'ı eğitim, %10'u test için kullanılmıştır. Çalışmaların sonuçları incelendiğinde dil modelleri ile yapılan çalışmaların doğruluk değerleri, makine öğrenmesi algoritmalarına göre

daha yüksek değerlere ulaşmıştır. Dil modellerinin başarı oranları DistilBERT , RoBERTa ve ALBERT olup elde edilen sonuçlar sırasıyla %80, %80 ve %77'dir . Makine öğrenmesi algoritmalarının sıralaması Naive Bayes, Destek Vektör Makinesi ve Rastgele Orman olup elde edilen sonuçlar %71, %68 ve %68'dir.

Öge ve Kayaalp [24] yapmış oldukları çalışmada, IMDB internet sayfasında yer alan film yorumlarından oluşan bir veri seti kullanmışlardır. Veri setinde 25.000 adet pozitif, 25.000 adet negatif olarak etiketlenmiş yorum bulunmaktadır. Python programlama dilindeki kütüphaneler kullanılarak Naive Bayes, Logistic Regression, Support Vector Machine, Decision Tree, Random Forest ve Artificial Neural Network sınıflandırma algoritmalarının duygu analizi kapsamında performans karşılaştırması yapılmıştır. Bag of Words, TF-IDF, Word2Vec ve FastText metin temsil yöntemleri kullanılarak temizlenmiş veri seti sayısal olarak temsil edilmiştir. Veri setinin eğitimi ve test edilmesi aşamasında k=5 olacak şekilde k-fold cross validation tekniği kullanılmıştır. 6 farklı sınıflandırma yöntemi için elde edilen sonuçlar doğruluk, kesinlik, geri çağırma ve F1 score hesaplanarak ayrıntılı bir karşılaştırma yapılmış ve sonuçlar kaydedilmiştir. Sonuçlar karşılaştırıldığında en iyi performans 0.87 doğruluk, 0.87 kesinlik, 0.88 tekrarlama değerleriyle 9.7 saniyede word2vec ile LR yöntemi kullanılarak elde edilmiştir.

Çalışma [30]'da Rumeli ve arkadaşları tarafından Türkçe metinler için bir duygu analizi modeli geliştirilmiştir. Bu model geliştirilirken, sözlük tabanlı yaklaşımlar ile makine öğrenmesi algoritmaları birlikte kullanılmıştır. Duygu analizinin en temel yöntemi olarak, cümledeki her kelimenin sözlükteki puan değerine bakarak toplama dayalı bir model ile hesaplama yapılmıştır. Makine öğrenmesi modelleri, metinlerin polarite puanlarını baz alarak doğru sonuçlar bulan duygu analizi yapmak için eğitilmiştir. Projede NB, RF, SVM ve k-NN algoritmaları olmak üzere dört farklı makine öğrenmesi yöntemi kullanıldı. NB ve

SVM için R dilindeki 'e1071' kütüphanesi kullanıldı. Bu paket, SVM algoritması için maliyet çekirdeği ve gama değerlerini değiştirmemize olanak tanır. Projede radyal, lineer ve polinom çekirdekler değiştirilerek model hayata geçirilmiş ve RF için "randomForest" isimli paket kullanılmış ve 'tree' parametresi 100, 425 ve 750 olarak değiştirilerek model eğitilmiştir. kNN algoritması için 'class' kütüphanesi kullanılmış ve k değeri sadece tek sayılar kontrol edilerek 3'ten 71'e çıkarılmıştır. Son olarak doğrulama setindeki performansı yüksek olduğundan k değeri 33 olarak belirlendi. Çapraz Doğrulamanın, makine öğrenimi yöntemlerinin değerlendirilmesi üzerinde önemli bir etkisi vardır. Bu nedenle 100 defa CV yapıldı. Veri setinin %80'i eğitim %20'si test verisi olarak bölündü. Tüm modellerin ortalama doğruluğu 0,73 civarında değişmektedir. Bu da modellerin doğrulukları arasında çok büyük bir fark olmadığını göstermektedir. NB ve kNN 1 dakikadan az sürede işlemi tamamlarken SVM ve RF'nin daha uzun süreye ihtiyacı olduğu gözlemlenmiştir.

Poornima ve Priya [26] yapmış oldukları çalışmada, twitter verilerini kullanarak cümle sınıflandırılmasında SVM, Multinomial Naive Bayes ve Logistic Regression performans karşılaştırılması yapmıştır. Twitter'dan alınan ham tweetler genellikle gürültülü bir veri kümesine neden olur. Çeşitli yöntemler kullanılarak veri seti temizlendi. Bigramlar kullanılarak veri kümesinden özellikler çıkarıldı. Bu özellikler, sınıflandırmada olumsuzluğu modellemek için etkili bir yol sağladı. Lojistik regresyonun doğruluğunun %86,23, destek vektör makinesinin doğruluğunun %85.69 ve Multinomial naïve bayes'in doğruluğunun %83,54 olduğu gözlemlenmiştir.

Sharma ve arkadaşlarının [35] yapmış oldukları çalışmanın amacı, çok terimli Naive Bayes, Destek Vektör Makineleri ve Lojistik Regresyon'dan yararlanarak duygu analizi çalışmalarında kullanılan tüm makine öğrenimi yaklaşımları için araştırma yapmak, karşılaştırma analizi yapmak ve performans değerlendirme verilerini sunmaktır. CNN ve LSTM gibi derin

öğrenme modellerinin fikir madenciliği ve duygu sınıflandırma görevlerini gerçekleştirmek için kullanıldığında diğer modellerden daha iyi performans gösterdiği görülebilmektedir. Makine öğrenimi modeli Rastgele Orman (RF) ve derin öğrenme modeli RNN'in performansı benzer olabilir, ancak sınıflandırıcıların veri kümelerine göre değişen eğilimleri vardır. Sonuçlara göre en iyi doğruluk oranı %93,5 ile CNN kullanılarak elde edilmiştir. Aynı veri kümesinde yapılan çalışmada LSTM %77.75 doğruluğa sahiptir.

Joshi ve arkadaşları [18] yapmış oldukları çalışmada, duygusal analiz ve kategorizasyon için Twitter verilerini kullanılmıştır. Duygu analizinin uygun veri görselleştirmesini ve ön işlemlerini kullanması, yürütmesi gereklidir. Makine öğrenimi algoritması kullanılarak olumlu veya olumsuz duyguların analizi yapılmıştır. Naive Bayes sınıflandırma algoritması kullanılmıştır. Verilerin kesinlik değerleri random forest yönteminde %75, karar ağacı yönteminde %75,36, eğitimde %84,93 testte ise %78.58 olduğu sonucuna ulaşılmıştır.

He ve arkadaşları [15] yapmış oldukları çalışmada, çevrimiçi ürün deneyimi elde etmeyi amaçlayan, metinsel analiz tekniklerini makine öğrenimi algoritmalarıyla birleştiren bir füz-
yon duyarlılığı analizi yöntemi geliştirdi. Yöntem temel olarak üç adımdan oluşmaktadır. İlk olarak, duygu sözlüğünün duygusal bilgiye duyarlılığından esinlenerek, sözlük duygu özelliklerini çıkarmak için kullanıldı. Daha sonra, incelemelerin duyarlılık kutuplarını belirlemek için SVM algoritması kullanıldı. Buna dayanarak, duyarlılık konuları LDA modeli aracılığıyla incelemelerden çıkarıldı. Ayrıca duygusal bilgilerin atlanmasını önlemek için sözlük anlamsal benzerliğe dayalı olarak genişletilmiştir. Tüketicilerin Amazon'daki çevrimiçi kitap okuma deneyimlerinin araştırılması, yöntemin uygulanabilirliğini ve geçerliliğini doğruladı. Sonuçlar, yöntemin incelemelerin duygusal eğilimlerini doğru bir şekilde belirlediğini ve incelemelerden okuma deneyimlerini etkileyen unsurları yakaladığını göstermektedir. Genel olarak araştırma, çevrimiçi ürün deneyimini araştırmak ve müşteri taleplerini takip etmek için

etkili bir yol sağlayarak gelecekteki ürün iyileştirme ve pazarlama stratejisi optimizasyonunu güçlü bir şekilde desteklemektedir.

Duygu analizi, yaklaşık 20 yıl önce ortaya çıkan bir alan olarak önemli gelişmeler kaydetmiş ve ticari uygulamalarda geniş bir kullanım alanına sahip olmuştur. Ancak, Poria ve arkadaşları [27] yapmış oldukları çalışmada da vurguladığı gibi, bu alanın olgunlaştığı algısına rağmen hala keşfedilmemiş ve yeterince araştırılmamış yönleri bulunmaktadır. Duygu analizi genellikle basit bir olumlu-olumsuz sınıflandırma görevi olarak algılandıkça çalışma, bu görevin aslında karmaşık ve çok yönlü olduğunu, insan güdülerini, niyetleri ve bağlamsal nüansları içerdiğini vurgular. Proje örnekleri, duyarlılık analizi, sarkazm analizi ve çok modlu duyarlılık analizi gibi alt alanlardaki çalışmaların önemine işaret ederken, bu çalışmaların duygu analizi alanında hala çözülmesi gereken sorunlara ışık tuttuğunu belirtir. Bu nedenle çalışma, duygu analizi alanındaki keşfedilmemiş potansiyeli vurgulayarak bu alanda daha fazla araştırma yapma çağrısında bulunmaktadır.

Radyo yayın hizmetlerinin hızla büyümesi, ses verilerinin artmasına neden olarak duygu analizini yeni bir boyuta taşımıştır. Dhariwal ve arkadaşları [11] yapmış oldukları çalışmada, sesli duygu analizi araçlarından transkripsiyon hizmetlerine ve doğal dil işleme tekniklerine kadar geniş bir yelpazede kullanılan hesaplama bir yaklaşım olan "çatallama ve karıştırma"yı önermeyi amaçlamaktadır. Metin duyarlılığı analizi sözlüklerini, AssemblyAI ve VADER gibi, ses verilerinden duyguları çıkarmak ve kategorilere ayırmak için kullanarak gerçek zamanlı duyarlılık analizi modeli oluşturmayı hedeflemektedir. Bu analizin sonuçları, tüm Hindistan Radyosu'nun 'Akashwani' tarafından yapılan radyo yayınlarında ifade edilen duygulardaki kalıpları ve eğilimleri ortaya koyarak haber servislerinin duygu analizi konusundaki yöntemlerini geliştirmeyi amaçlamaktadır. Metin duyarlılığı analizi ve sesli duyarlılık analizi arasındaki avantaj ve dezavantajları değerlendiren araştırma, bu iki yöntemin

birleşimiyle daha kapsamlı ve etkili bir sonuç elde edilebileceğini ortaya koymaktadır. Ayrıca, bu çalışmanın gelecekte afet yönetimi gibi gerçek dünya sorunlarına çözüm bulmak ve radyo sinyallerinin kullanıldığı iletişimdeki rolünü güçlendirmek adına önemli bir araştırma kaynağı olabileceği vurgulanmaktadır. Ancak, analiz modellerini çalıştıran bağımsız bir sistem geliştirmenin zorlukları, modelin eğitildiği veri setinin kalitesi ve çeşitliliği, afet yönetimi durumlarında kullanılacak olan NVV veri setlerinin ihtiyaçları gibi konular da ele alınmalıdır.

Li ve arkadaşları [22] yapmış oldukları çalışmada, canlı yorumlama platformu Danmaku üzerine odaklanmıştır. Danmaku, kullanıcıların videoları izlerken gerçek zamanlı yorumlar yapabildikleri bir sistemdir. Ancak, mevcut duygu sınıflandırma yöntemleri Danmaku verileri için uygun değildir. Bu sorunu çözmek için makalede bir duygu sözlüğü oluşturulmuş ve Naive Bayes tabanlı yeni bir yöntem önerilmiştir. Tencent Video'dan seçilen Danmaku verileri üzerinde yapılan testler, önerilen SDD-NB modelinin diğerlerine göre %14.8 daha yüksek doğruluk oranına sahip olduğunu göstermiştir.

Fu ve arkadaşları [12] yapmış oldukları çalışmada, duygu analizi için kullanılan LSTM'lerin başarılı bir yöntem olarak vurgulandığını ancak yalnızca kelime gömülerinin yetersiz olduğunu belirtmiştir. Bu eksikliği gidermek amacıyla LE-LSTM adlı bir sözlük ile geliştirilmiş LSTM modeli önerilmiştir. GloVe kullanılarak yapılan deneylerde, LE-LSTM'nin standart LSTM modeline kıyasla 2 daha yüksek doğruluk elde ettiği gözlemlenmiştir. Ayrıca, duygu kelimesinin dil bilimsel rolünü modellemek için kayıp fonksiyonuna düzenleyici eklenmesi ve farklı boyutlardaki CNN mimarisi de metin kategorizasyonu için önerilmiştir. Gerçekleştirilen deneyler, LE-LSTM, Bi-LSTM ve Tree-LSTM modellerinin tüm veri kümelerinde standart LSTM'den daha iyi performans sergilediğini göstermiştir. Bu modellerin test edildiği beş veri kümesi (IMDB, Yelp2013, NB4000, MR ve Book4000) üzerinde elde edilen

sonuçlar, özellikle LE-LSTM'nin diğer modellere göre daha etkili olduğunu ortaya koymuştur. Bu önerilen model, kelime gömülerinin anlamsal bilgi taşıma sorununu çözmek ve duygu analizi performansını artırmak için etkili bir yöntem sunmaktadır.

Wang ve arkadaşları [39] yapmış oldukları çalışmada, geleneksel kelime gösterimine duygu bilgisi ekleyememe sorununu çözmek amacıyla Word2Vec ve GloVe temelli RGWE yöntemini önermektedir. RGWE, duyarlılık, konum ve POS özelliklerini ekleyerek duygu analizinin doğruluğunu artırmayı hedeflemektedir. RGWE, SSWE ve Seninfo+TF-IDF'ye göre daha iyi bir performans sergileyerek, ikili sınıflandırma, üçlü sınıflandırma ve CNN için sırasıyla %89.86, %69.1 ve %48.85 ortalama F1 değerleri elde edilmiştir. Bu başarı, SemEval, SST1, SST2, IMDB, Amazon ve Yelp gibi altı klasik veri kümesi üzerinde gözlemlenmiştir. RGWE, duygusal içerikli metin analizi için güçlü bir kelime gömme teknolojisi olarak öne çıkmaktadır.

Zhang ve Zheng [41] yapmış oldukları çalışmada, Çince metinlerde duygu analizini ele almakta olup, TF-IDF ile ağırlıklı özellik hesaplaması kullanılarak olumlu ve olumsuz duygusal eğilimleri sınıflandırmaktadır. SVM ve ELM çekirdekli modeli, eğitim örnek kümesini öğrenerek test kümesinde duygu sınıflandırması yapmıştır. ELM, yüksek verimliliği ve uygulanabilirliği ile duygu analizi alanında önemli bir konudur. Veri seti olarak oluşturulan metin dosyaları kullanılmış ve denoising, segmentasyon ve durdurma kelimesi filtreleme adımları gerçekleştirilmiştir. TF-IDF kullanılarak belgeler arasındaki fark belirlenmiştir. Simülasyonlar, MATLAB ortamında gerçekleştirilmiştir. Deney sonuçları bölümünde, Çince metinlerden oluşan bir derlemin duygu analizi için çekirdekli ELM'nin performansı değerlendirilmiştir. Aynı zamanda bu sonuçlar, benzer bir sınıflandırma görevi için yaygın olarak kullanılan Destek Vektör Makinesi ile karşılaştırılmıştır. Sonuçlar, çekirdekli ELM'nin Çince metinlerde duygu analizi uygulamalarında daha etkili bir çözüm sunduğunu göstermektedir. Hem doğru-

luk oranları hem de eğitim-test süreleri açısından çekirdekli ELM, SVM'ye kıyasla avantajlı bir performans sergilemektedir.

Xu ve Song [40] yapmış oldukları çalışmada, metin duygu sınıflandırması alanında geleneksel ve derin öğrenme modellerini aşan yeni bir yaklaşım sunmaktadır. BERT ile birleştirilmiş iki hibrit sinir ağı modeli tanıtılarak, Chnsenticrop ve Weibo veri kümeleri üzerinde eğitilen bu model, temizlenmiş ve SST-2 formatına dönüştürülmüş verilerle 4:1 oranında eğitim-test setlerine ayrılmıştır. Kelime tabanlı metinler, 512 boyutlu Word2Vec vektörleri kullanılarak temsil edilmiştir. Çeşitli yöntemler, örneğin CNN, LSTM, GRU, Bert+BiLSTM ve Bert+CNN, karşılaştırılarak en etkili yaklaşım belirlenmiştir. Bert+CNN modeli, diğerlerine göre daha yüksek doğruluk, geri çağırma ve F1 skorlarına sahip olduğunu göstererek ön plana çıkmıştır. LSTM en yüksek geri çağırma oranını, GRU ise en yüksek F1 puanını elde etmiştir. Analiz sonuçları, metin duygu sınıflandırmasında Bert+CNN modelinin etkili bir performans sergilediğini ortaya koymaktadır.

Rizk ve Asal [29] yapmış oldukları çalışmada, çeşitli makine öğrenimi, sinir ağları ve kelime gömme modellerini değerlendiren kapsamlı bir çalışmanın özetini sunmaktadır. Araştırma, BERT katıştırmaları ile LSM-çift yönlü kodlama modelinin en yüksek test doğruluğuna ulaştığını ve kelime gövdeleri ile derin öğrenme mimarilerinin geleneksel modellere göre üstün performans sergilediğini göstermektedir. Ayrıca, Word2Vec'in farklı modellerle birleştirilmesini inceleyen çalışma, bu hibrit yaklaşımın %89.2'lik bir doğruluk oranıyla diğer modellere göre daha etkili olduğunu ortaya koymaktadır. DistilBERT adlı önceden eğitilmiş bir dil modelinin tanıtıldığı ve orijinal BERT'e kıyasla %40 daha küçük, %97 oranında bilgi koruyabilen ve %60 daha hızlı olduğu kanıtlanmıştır. Araştırma, IMDB film incelemeleri üzerinde yapılan denemelerde Transformatörden Çift Yönlü Kodlayıcı Temsilleri (BERT) gömülü Uzun Kısa Süreli Bellek (LSTM) modelinin %93'lük doğrulukla en iyi performansı

sergilediği sonucuna ulaşmıştır. Bu bağlamda, DistilBERT'in daha küçük boyutta ve hızlı çalıştığı vurgulanmıştır.

Hammad ve Anwar [13] yapmış oldukları çalışmada, Sindhi dilinde duygu analizi gerçekleştirmek için denetimli makine öğrenimi tekniklerini kullanmıştır. Sindhi tweetlerini içeren bir veri kümesi, önceden tanımlanmış sözlüksel veri tabanı ve Google Translate API yardımıyla etiketlenmiştir. Veri kümesi, temizlenmiş ve tokenizasyon işleminden geçirilmiştir. Duygu analizi için SVM, NB, DT ve k-NN algoritmaları kullanılmıştır. Elde edilen sonuçlar, Sindhi tweet veri setinde DT ve k-NN algoritmalarının iyi bir performans sergilediğini, SVM'nin bunları takip ettiğini göstermektedir. Özellikle SVM, doğruluk, kesinlik, geri çağırma ve F1 puanı ölçütlerinde yüksek bir performans sergilemiştir. Veri kümesi boyutları arttıkça doğruluk değerlerinin arttığı ancak kesinlik ve geri çağırma değerlerinin değişkenlik gösterdiği gözlemlenmiştir. Bu bağlamda, Sindhi dilinde duygu analizi için denetimli makine öğrenimi yöntemlerini değerlendiren bu araştırma, özellikle SVM'nin yüksek performans gösterdiğini vurgulamıştır.

Pandya ve arkadaşları [25] yapmış oldukları çalışmada, Makine Öğrenimi ve Derin Öğrenme modelleri kullanılarak Twitter duygu analizi yapmayı hedeflemiştir. 1.6 milyon tweet bu çalışmanın veri kümesi olarak kullanılmıştır. Tweetler olumlu veya olumsuz duygulara göre sınıflandırılmıştır. Bunun için Naive Bayes ve Destek Vektör Makineleri gibi geleneksel makine öğrenimi modelleri kullanılmıştır. Makine öğrenimi ve derin öğrenme modellerini eğitmek için Sentiment140 veri kümesi kullanılmış olup bu küme 800.000 negatif, 800.000 pozitif tweet kümesinden oluşmaktadır. Eldeki veriler ön işleme tabi tutulmuştur. Tweetlerden kullanıcı adı, bağlantı, noktalama işaretleri, rakam, stopwords gibi ifadeler kaldırılmış bütün harfler küçük harfe dönüştürülmüştür. Daha sonra bu veriler köklerine ayrıştırılmıştır. Elde edilen veri kümesi görselleştirilerek negatif ve pozitif kelime bulutu oluşturulmuştur.

Veri kümesi kelimelerden oluştuğu için vektöre dönüştürmek amacıyla Word2Vec modeli kullanılmıştır. Bu veri kümesi %80 eğitim %20 test olarak iki ayrı kümeye dönüştürülmüştür. Toplam tweet sayısı üzerinden 1.28 milyon tweet eğitim için, 320.000 tweet test için kullanılmıştır. Model eğitimlerinde NB, SVM, RNN, LSTM VE Bi-LSTM kullanılmıştır. Sonuçlar doğruluk, F1 skoru, geri çağırma skoru ve hassasiyete göre karşılaştırılmıştır. Destek Vektör Makinesinin %76.53 doğrulukla daha iyi performans verdiği gözlemlenmiştir. Fakat Derin öğrenme modelleri makine öğrenimi modeline göre daha iyi performans göstermiştir.

Singh ve arkadaşları [36] yapmış oldukları çalışmada, TF-IDF ve makine öğrenimi algoritmalarını kullanmıştır. Veri kümesi olarak ABD Havayolları duyarlılık tweetleri kullanılmıştır. Tweetler olumlu olumsuz ve nötr olmak üzere üç kategoride sınıflandırılmıştır. Veriler önce pre-processing denilen ön işleme tabi tutulmuştur. Gereksiz kelimeler, noktalama işaretleri gibi karakterler silinmiş, büyük harfler küçük harflere dönüştürülmüştür. Geriye kalan metin daha küçük parçalara bölünerek verilere tokenizasyon işlemi uygulanmıştır. Daha sonra sözcüklerin köküne indirgemek için stemming işlemi yapılmıştır. Kalan verilere TF-IDF yöntemi uygulanarak kelimelerin uygulanma sıklığı elde edilmiştir. 80:20 kuralı uygulanmıştır. Bu çalışmada RF, GB XGBoost ve SV olmak üzere dört tane sınıflandırma tekniği doğruluk, hassasiyet, hatırlama ve F1 Skoru'na göre karşılaştırılmıştır. SVM'nin %83.74 oran ile en yüksek doğruluğu elde ettiği görülmektedir. Aynı zamanda %84 hassasiyet ve % 87.85 F1 skoru ile diğer tekniklerden daha iyi sonuç vermiştir.

Kim [21] yapmış olduğu çalışmada, müşteri yorumlarının inovasyon yöneticileri için önemli bir kaynak olduğunu vurgulayarak, duygu analizinin bu yorumlardan elde edilen istatistiksel verilerle mümkün olduğu bir perspektife odaklanmıştır. Metin madenciliği yöntemlerini kullanarak müşteri duyarlılığını değerlendirmek amacıyla çeşitli ölçütler önerilmekte ve Linguistic Inquiry and Word Count (LIWC) gibi metin madenciliği paketleri üzerindeki

alternatifler incelenmiştir. Duyarlılık analizi için pozitif ve negatif eğilimli kelimelerin sayılarına dayanan bir yaklaşım benimsenmiş ve bu yöntemlerin sınırlamaları tartışılmıştır. Çalışma, duyarlılık puanları ile çevrimiçi inceleme derecelendirmeleri arasındaki dağılım farkını göstererek özellikle çevrimiçi derecelendirmelerin öznel olduğunu vurgulamıştır. Ayrıca, pazarlamacıların müşteri görüşlerini değerlendirmek ve karşılaştırmak için duyarlılık puanlarını kullanabileceği alternatif yollar sunmuştur. Sonuç olarak metin madenciliği ve duygu analizinin, pazarlamacılara müşteri geri bildirimlerini etkili bir şekilde değerlendirme ve inovasyon performanslarını ölçme konusunda yardımcı olabileceğini öne sürmüştür.

Chandra ve Jana [8] yapmış oldukları çalışmada, duygu analizi konusundaki araştırmalara ve kullanılan yöntemlere odaklanarak insanların görüşlerini, duygularını ve tutumlarını belirli konularla ilişkilendiren bir alana odaklanmıştır. Makine öğrenimi ve derin öğrenme tekniklerinin dil işleme istatistiksel yöntemleriyle birleştirilmesi, duygu analizinin gelişimine önemli katkı sağlamıştır. Sosyal medyanın etkisi ve kullanıcıların duygularını dijital medya aracılığıyla ifade etmeleri, özellikle Twitter gibi platformlarda zengin bir veri kaynağı oluşturmaktadır. Duygu analizi için kullanılan çeşitli yöntemler ve teknikler, duyarlılık sözlüklerinin algoritmik oluşturulması, duyarlılık endeksi oluşturma ve önem değerlendirmesi gibi aşamaları kapsamaktadır. Çalışma, bu yöntemlerin yanı sıra derin öğrenme modelleri ve makine öğrenimi sınıflandırıcıları kullanarak gerçekleştirilen duygu analizi için önerilen yaklaşımları detaylı bir şekilde açıklamaktadır. Derin öğrenme modelleriyle yapılan deneylerde, çeşitli modellerin performansları karşılaştırılmış ve LSTM-CNN'nin en iyi sınıflandırma sonuçlarını verdiği sonucuna varılmıştır. Deneyler ve sonuçların analizi bölümünde, Twitter API ve çeşitli konulardaki veri kümeleri kullanılarak gerçekleştirilen deneylerin sonuçlarına odaklanılmıştır. Makine öğrenimi modellerinin doğruluk yüzdesinin 81 ila 90 arasında kaldığı belirtilirken derin öğrenme modellerinin %85 ila %97 aralığında daha iyi sonuçlar elde

ettiği vurgulanmıştır. Sonuç ve gelecek kapsamı bölümünde, derin öğrenme modellerinin daha iyi performans gösterdiği ve gelecekte bu alanda yapılacak çalışmaların bu modellerin tasarımı ve uygulanması üzerine odaklanabileceği sonucuna varılmıştır. Sosyal medya verilerinin analizi, işletmelere bilgilendirici içgörüler ve gelir sağlama potansiyeli sunabilir.

Saraswat ve arkadaşları [32] yapmış oldukları çalışmada, ses dosyalarının makine öğrenimi kullanılarak duygu analizi yapılması ve ses verilerinin metinsel sınıflandırma ile analiz edilmesi hedeflenmiştir. Duygu analizi, metin madenciliği teknikleri ile genellikle işlenen verilere odaklanmıştır. Ancak ses verilerinin duygu analizi alanındaki araştırmalar hala erken aşamadır. Ses verilerinin analizinde kullanılan temel özellikler arasında ses frekansı, konuşma öznitelikleri ve zamansal öznitelikler bulunmaktadır. Projenin temelini oluşturan sistem mimarisi, ses dosyalarından metin transkriptleri oluşturmayı içermektedir. Bu transkriptler daha sonra çeşitli metin madenciliği araçları kullanılarak işlenir. Metin verileri analize hazırlanırken önce ses dosyalarının metne dönüştürülmesi, ardından ön işleme adımları ile belirli bir özellik kümesinin çıkarılması gerçekleştirilir. Son olarak, denetimli öğrenme teknikleri kullanılarak metin transkriptleri kategorize edilir. Naïve Bayes, Lojistik Regresyon ve Sayım Vektörleştirici gibi çeşitli sınıflandırma algoritmaları kullanılarak duygu analizi gerçekleştirilir. Naïve Bayes sınıflandırıcısı kullanılarak elde edilen sonuçlar, özellikle pozitif ve nötr duyguların tanınmasında yüksek doğruluk göstermektedir. Duygu analizörü, çeşitli duyguları tanıma doğruluğuyla şu sonuçları vermektedir: Neşe %94, Üzüntü %93, Öfke %85, Korku %74, İğrenme %70, Utanç %56, Sürpriz %52. Duygu analizörünün başarı oranının, güçlü duygusal değerlere sahip kelimelerin konuşmada belirgin bir şekilde kullanılmasına bağlı olduğu gözlemlenmiştir. Bu kelimeler, tahmin skorunu ve doğruluğunu etkilemede önemli bir rol oynamaktadır. Model, 34,000’den fazla veri noktası üzerinde eğitildiği için %86’lık bir doğruluk sağlamaktadır, bu da diğer ses duygu analizörlerine kıyasla (metinsel sı-

nıflandırma tabanlı ve harici donanım cihazına ihtiyaç duymadan) oldukça yüksektir. Daha büyük veri setleri ve gelişmiş veri temizleme teknikleri kullanılarak gelecekteki çalışmalar, duygu analizi alanında daha kesin ve güvenilir sonuçlara ulaşabilir.

Can ve Alataş [7] yapmış oldukları çalışmada, sosyal medyanın ve genel olarak internet sosyal ağlarının günümüzde giderek önem kazanması ile beraber popüler bir konu haline gelmiş duygu analizini genel olarak anlatmış ve bu konuda yapılan çalışmalarda ortaya konulan duygu analizi algoritmalarını ve uygulamalarını göstermiştir. Güncel bir sonuç çıkarmak amacı ile son yıllarda yapılan çalışmalar ele alınmıştır. Daha sonra bu çalışmalar kategorize edilerek gösterilmiş ve kısaca özetlenmişlerdir. Bu çalışmalar gerçek dünya problemlerine duygu analizi tekniklerini uygulayarak duygu analizi ile ilgili birçok alana katkı sunmuştur. Tüm bu çalışmaların incelenmesinden sonra duygu sınıflandırması ve özellik seçimi algoritmalarının geliştirilmesinin halen önemli bir çalışma alanı olduğu açıkça görülmektedir. Ayrıca duygu sınıflandırma problemlerinin çözümünde Naive Bayes ve Destek Vektör Makineleri'nin en çok kullanılan makine öğrenme algoritmaları olduğu sonucu da ortaya çıkmıştır. Yapılan analizler sonucunda İngilizce dilinde birçok çalışma ve bunların doğal sonucu olarak birçok kaynak olduğu ortaya çıkmıştır. İngilizce dışındaki dillerde ise çalışma ve kaynak eksikliğinin olduğu görülmüştür. İngilizcenin dışında en çok kullanılan veri kaynağı WordNet olmuştur. Duygu analizi çalışmaları için son zamanlarda yeni bilgi kaynakları ortaya çıkmıştır. Bu kaynaklar mikro-blog, bloglar ve forumlar olmuştur. Tüm bu kaynaklar insanların belli güncel konular hakkında ne düşündükleri ve bu konularla ilgili duygularının anlaşılması için önemli bir rol oynamaktadır. Daha derin ve detaylı analizler için sosyal ağ siteleri ve mikro-bloglar önemli kaynaklar olmaktadır. Ayrıca algoritmaların test edilmesi için birçok veri seti de mevcuttur. Yapılan bu çalışmada duygu analizi konusunda

halen tartışmaya açık alanlar olduğu görülmüştür. Genel çalışma alanlarına ek olarak Türkçe konusunda yapılan çalışmalar halen yetersizdir.

Satrya ve arkadaşları [34] yapmış oldukları çalışmada, Twitter üzerindeki kripto para birimleri ile ilgili olumlu ve olumsuz eğilimleri inceleyerek, toplumun bu dijital varlıklara yönelik tutumlarını anlamayı amaçlamıştır. Duygu analizi veya fikir madenciliği yöntemleri kullanılarak Twitter'daki veriler sınıflandırılarak olumlu ve olumsuz eğilimler ortaya çıkarılmaya çalışılmıştır. Bu analiz, özellikle Bitcoin'e odaklanarak kripto para birimlerinin genel algısını belirleyebilir ve yatırımcılar ile işletmeler için önemli bir referans olabilir. Daha önceki çalışmaların incelenmesine dayanarak bu çalışmada Destek Vektör Makinesi algoritması kullanılmıştır. Literatürde SVM'nin duygu analizi konusunda yüksek doğruluk sağladığı belirtilmiştir. Araştırmacılar, elde edilen Twitter verilerini SVM kullanarak sınıflandırarak olumlu ve olumsuz eğilimlere dair sonuçlar elde etmeyi hedeflemiştir. Yöntem olarak, veri toplama işlemi Twint kütüphanesi kullanılarak gerçekleştirilmiş ve Twitter API'sine gerek duyulmamıştır. Elde edilen veriler öncelikle temizlenmiş ve duygu analizi için uygun hale getirilmiştir. Veri kümesinin dengesizliği, alt örnekleme yöntemi kullanılarak ele alınmış ve analiz için hazırlanan veriler SVM algoritmasıyla işlenmiştir. Sonuçlar, kullanılan yöntemin yüksek doğruluk değerleri elde ettiğini göstermiştir. 80:20 oranında eğitim-test bölme durumunda en yüksek doğruluk %94,64 olarak bulunmuştur. Hassasiyet, özgüllük ve F1 skoru gibi değerler de incelendiğinde SVM algoritmasının kripto para duygu analizi konusunda etkili bir araç olduğu görülmüştür. Bu sayısal değerler, analizin güvenilirliğini ve gerçek dünya uygulamalarındaki potansiyel etkisini daha fazla vurgulamaktadır.

Sarkar ve Bhowmick [33] yapmış oldukları çalışmada, Bengalce tweetler üzerine araştırma yapmıştır. Ön işleme ve duygu kutupluluğu tespiti için sınıflandırıcı olarak Multinomial Naive Bayes ve SVM kullanılmıştır. N-gram Tokenizer ve SentiWordnet kullanılmıştır. Veri-

ler olumluluk, olumsuzluk ve tarafsızlık olarak üç duyarlılık puanına göre sınılandırılmıştır. Öncelikle veriler ön işleme tabi tutulmuştur. Etiketli vektörlerle bir sınıflandırıcı eğitilmiş daha sonra model tweetler üzerinde kullanılmak üzere kaydedilmiştir. Bengalce veri kümesi kullanılmıştır. Eğitim veri kümesi 356 negatif, 368 pozitif, 276 nötr tweet ve test veri kümesi olarak 500 etiketlenmemiş tweet olarak toplamda 1500 adet tweetten oluşmaktadır. Deney sonuçlarına bakıldığında Naive Bayes multinomial unigram, bigram, SentiWordnet kullanarak %44.20 ile en iyi sonuçları vermiştir. SVM ise unigram ve SentiWordnet özelliklerini kullanarak %45 ile en iyi sonuçları verdiği gözlemlenmiştir. Önerilen modeller SAIL 2015 yarışmasına katılan en iyi tweet duyarlılık tespit sistemleri ile karşılaştırılmış olup SVM tabanlı sistemin bu yarışmadaki en iyi sistemden daha iyi performans gösterdiği ortaya konulmuştur.

Jayakody ve Kumara [17] yapmış oldukları çalışmada, Twitter'daki ürün incelemelerini kullanarak duygu analizi üzerinde çalışma yapmışlar. Veri olarak 3548 açıklamalı tweet kullanılmıştır. İki farklı vektörleştirme yöntemi kullanılarak üç denetimli makine öğrenimi modeli karşılaştırılmıştır. Veriler; SVM, Logistic Regression, K-Nearest Neighbor algoritmaları kullanılarak sınıflandırılmıştır. Vektörleştirici olarak TF-IDF ve Sayım Vektörleştirici kullanılmıştır. Veriler olumlu-olumsuz duygulara göre ayrıştırılmıştır. Tweetler pozitif olanlar 1, negatif olanlar ise 0 şeklinde etiketlenmiştir. Daha sonra boş tweetler kaldırılarak kalan tweetler üstünden istenmeyen içerikler silinmiştir. 2 kelimedenden daha az tweetlerde silinerek kalan metinler küçük harfe dönüştürülüp veri hazırlama aşaması tamamlanmıştır. Eldeki veri kümesi eğitim ve test olmak üzere iki veri kümesine ayrılmıştır. Eğitim veri kümesinin oranı %70, test veri kümesinin oranı ise %30 olarak bildirilmiştir. Makine Öğrenimi algoritmaları kullanılarak sonuçlar elde edilmiştir. Elde edilen sonuçlara bakıldığında Sayım Vektörleştirici kullanılarak yapılan çalışmada Lojistik Regresyonun diğer algoritmalara göre daha iyi sonuç verdiği görülmektedir. TF-IDF kullanılarak yapılan çalışmada ise SVM algoritması-

nın %87.41 ile diğer algoritmalara kıyasla daha iyi sonuç verdiği gözlemlenmiştir. Diğer bir çalışma olarak veri kümesinin bölünmesinin sonuca etkisini belirlemek için eğitim ve test olmak üzere her ikisi de %50 oranla bölünmüş ve çalışma uygulanmıştır. Sayım vektörleştirici kullanıldığında Lojistik Regresyon, TF-IDF kullanıldığında SVM algoritması daha iyi sonuç vermiştir. KNN algoritması her iki çalışma içinde benzer sonuçlar vermiştir. En doğru sonuçları ise %87.2 doğruluk oranı ile Sayım Vektörleştirici kullanılan Lojistik Regresyon algoritması vermiştir. Genel sonucun veri bölme işleminden etkilenmediği görülmektedir.

Bhasin ve Das [6] yapmış oldukları çalışmada, Apache Hadoop ile makine öğrenimi teknikleri incelemiştir. Çalışmada ilk olarak hashtag temelinde tweetler toplanmış daha sonra bir ön işlemden geçirilmiştir. Özellik çıkarımı yapılmıştır. Makine öğrenimi modellerinden LR, NB ve SVM kullanılmıştır. Hadoop büyük verileri işlemek için kullanılan açık kaynaklı bir framework olarak tanımlanmıştır. Map-Reduce algoritması bir Hadoop modülü olarak üç aşamadan oluşmaktadır; Eşleyici aşaması, Karıştırma aşaması ve İndirgeyici aşaması. Eşleyici aşaması tweetlerin girdi olarak alınıp yöntemlenir. Karıştırma aşaması karıştırma, kopyalama ve sıralama olarak üç aşamaya ayrılmaktadır. İndirgeyici aşama ise tweetlerin pozitif ve negatif olarak belirlendiği aşamadır. Hadoop Dağıtılmış Dosya Sistemi, bir dosya sisteminin bilgisayarlar üzerinde çalışmasını sağlayan sistemdir. Apache Spark Map Reduce'un kısıtlamalarını kaldırmak için tasarlanan toplu reduce seçimi olarak tanımlanmaktadır. Hızlı sorgu yapmak için kullanılmaktadır. Çalışmanın sonucunda veri kümesinin boyutu çok büyük olduğu zaman Naive Bayes makine öğrenimi algoritması diğer algoritmalara göre daha sağlamdır.

Jagadeesan ve arkadaşları [16] yapmış oldukları çalışmada, Twitter duygu analizi gerçekleştirmek için makine öğrenimi yöntemi kullanmıştır. Çalışmanın amacı makine öğrenimi yöntemi kullanılarak twitter'daki ırkçı, kadın düşmanı, dine ve mültecilere karşı yapılan nef-

ret söylemlerinin tespit edilip tanımlamaktır. Metodoloji dört adımdan oluşmaktadır. İlk adım olarak veri koleksiyonlarını toplamaktır. Daha sonra bu koleksiyonları ön işleme tabi tutup istenmeyen karakterler metinden kaldırılmıştır. Tokenizasyon uygulanmıştır. Lemmatizasyon ve stemming uygulanarak bir kelimenin bütün alternatiflerini bir kategoride sınıflandırıp kelimenin köküne yoğunlaşmıştır. İkisi de Doğal Dil İşleme yaklaşımıdır. Üçüncü adım olarak özellik çıkarma uygulanmıştır. Son adım olarak duygu sınıflandırılması yapılmıştır. Bu adım Rastgele Orman Sınıflandırıcı, Lojistik Regresyon, Karar Ağacı Sınıflandırıcı, Destek Vektör Makinesi ve XGBoost Sınıflandırıcı olmak üzere beş algoritma ile deneyler yapılmıştır. Hata matrisi oluşturularak doğruluk oranları incelenmiştir. Sonuçlara bakıldığında doğruluk oranı %95 ile Rastgele Orman ve Destek Vektör Makinesi algoritması en iyi sonucu vermiştir.

Aytuğ [4] yapmış olduğu çalışmada, Twitter üzerinde duygu analizi için psikodilbilimsel bir yaklaşım benimsenmiş ve çeşitli metodolojik adımlar takip etmiştir. Veri seti, İngilizce tweet'lerden oluşmakta olup olumlu, olumsuz ve nötr duygular içermektedir. Toplamda 13,361 tweet içeren veri seti, dengeli bir şekilde etiketlenmiş 4200 negatif, 4200 pozitif ve 4200 nötr tweet içermektedir. Veri Seti Koleksiyonu aşamasında, Twitter Streaming API ve Twitter4J kütüphanesi kullanılarak tweet'ler toplanmıştır. Veri Ön İşleme aşamasında, tweet'lerin düzensiz ve gayri resmi doğası dikkate alınarak, baş harfler, gereksiz tekrarlar ve yanlış kullanılan harfler gibi belirli sorunlar ortadan kaldırılmıştır. Özellik Mühendisliği aşamasında, duygu analizi için psikodilbilimsel özellikler çıkarmak amacıyla LIWC (Dil bilimsel Sorgulama ve Kelime Sayısı) kullanılmıştır. Bu çerçevede, dilin duygusal, bilişsel ve yapısal yönlerini tanımlamak için kullanılan bir metin analizi uygulamasıdır. Sınıflandırma Algoritmaları aşamasında, çeşitli özellik mühendisliği şemalarının tahmin performansını değerlendirmek için Naïve Bayes, Destek Vektör Makineleri, k-En Yakın Komşu algoritması ve Lojistik Regresyon kullanılmıştır. Naïve Bayes algoritması, en yüksek tahmin performan-

sını sağlamıştır. Ensemble Öğrenme Yöntemleri aşamasında, topluluk öğrenme algoritmaları olan Bagging, AdaBoost ve Rastgele Altuzay yöntemleri kullanılmıştır. Bagging, farklı eğitim setleri üzerinde eğitilmiş zayıf öğrenme algoritmalarını birleştirerek daha yüksek tahmin performansı elde etmeyi amaçlayan bir yöntemdir. AdaBoost, sınıflandırılması zor olan veri noktalarına odaklanarak sağlam bir sınıflandırma şeması elde etmeyi amaçlamaktadır. Rastgele Altuzay yöntemi, rastgele seçilen özellik altuzayları üzerinde eğitilen birden fazla sınıflandırıcıyı birleştiren bir topluluk öğrenme algoritmasıdır. Deney analizi ve sonuçlar aşamasında, 10 kat çapraz doğrulama yöntemi kullanılarak çeşitli özellik kümeleri ve sınıflandırıcılarla yapılan deneyler değerlendirilmiştir. Psikodilbilimsel özelliklerin ve topluluk öğrenme yöntemlerinin duygu analizi performansını arttırdığı gözlemlenmiştir. Özellikle, dilbilimsel süreçler, psikolojik süreçler ve kişisel kaygıların birleştirildiği topluluk özellik kümeleri, Naïve Bayes sınıflandırıcısı ile birlikte kullanıldığında %89,10'luk bir sınıflandırma doğruluğu elde edilmiştir. F-skoru sonuçları da sınıflandırma doğrulukları ile paralellik göstermiştir. Bu çalışmanın sonuçları, Twitter verilerinde duygu analizi için psikodilbilimsel özelliklerin etkili bir şekilde kullanılabileceğini ve topluluk öğrenme yöntemlerinin sınıflandırma algoritmalarının performansını arttırabileceğini göstermektedir.

Kemaloğlu ve arkadaşları [20] yapmış oldukları çalışmada, Facebook, Twitter, Instagram, YouTube ve Rss verilerini kullanarak duygu analizi üzerinde çalışmışlardır. LSTM modeli, özellikle Twitter verileriyle eğitilen modeller arasında en yüksek doğruluk oranını elde etmiştir. Multinomial Naive Bayes ise %86.06 başarı oranıyla dikkat çekmektedir. Rastgele Orman algoritması, kelime tabanlı yöntemlerde %89.5 başarı sağlamış. Ancak özellikle TF-IDF kullanılarak geliştirilen LSTM modeli %83.3 başarı oranı sağlamıştır. Bu çalışmada, 5 farklı sosyal medya platformundan API'ler kullanılarak veri toplanmış ve veri seti %30 test, %70 eğitim verisi olarak ayrılmıştır. Python tabanlı bir yazılım kullanılarak geliştirilen

sistemde, numpy, pandas, keras ve scikit-learn gibi kütüphaneler kullanılmıştır. Analiz sonuçlarına göre, en yüksek başarı oranı %84.46 ile LSTM modelinden elde edilmiş ve bu nedenle geliştirilen sistemle birlikte kullanılmak üzere LSTM modeli tercih edilmiştir.

Hassan ve arkadaşları [14] yapmış oldukları çalışmada, tweetlerin duyarlılık analizini kullanarak COVID-19 salgınına tespit etmeye yönelik bir araştırma yaptılar. Bu bağlamda Twitter veri kaynağı olarak seçildi ve COVID-19 ile ilgili anahtar kelimeler içeren birçok tweet toplandı. Toplanan bu veriyi daha sonra filtrelemek ve iki etikete ayırmak amacıyla farklı ön işleme teknikleri uygulandı. Bu tekniklerden biri geçerli veriyi temsil ederken diğeri geçersiz veriyi ifade etmektedir. Ön işlemeden sonra ait olduğu verinin bir dizi kategorisini tanımlamak için sınıflandırma algoritmaları kullandılar. Sınıflandırma için Karar Ağacı Algoritmasını, Naïve Bayes Algoritmasını ve Destek Vektör Makinesi Algoritmasını kullandılar. Deneylerimiz için en uygun yolu belirlemek amacıyla dört farklı k-kat değeri kullanıldı. Bu adımı, araştırmanın doğruluk testlerini uyguladığı performans değerlendirme adımı izlendi. Deneylerden, SVM'nin verilerin doğruluk açısından sınıflandırılmasına en uygun olduğu gözlemlenmiştir. Bu araştırma, COVID-19 hastası olan ve herhangi bir nedenle test yapılmayan hastaları tespit etmek için bu tür bir yaklaşımın kullanabileceğini gösteriyor.

Li ve arkadaşlarının [23] üzerinde çalıştığı çalışma, Çince üzerinden yürütülmüştür ve duygular 7 ana kategoride sınıflandırılmıştır. Bu ana kategoriler 2 ana duygu kategorisinde birleştirilmiştir. “Mutlu” ve “iyi” ifadeleri olumlu duygu; “üzgün”, “kızgın”, “korkmuş” ve “şaşkın” olumsuz duygu olarak sınıflandırılmıştır. Olumlu duygular sıfır puandan büyük, olumsuz duygular sıfır puandan küçük ve nötr duygular ise sıfır puan olarak değerlendirilmiştir. Bu çalışmada bazı kurallar uygulanmıştır. Bu kuralların ilki, olumsuz bir kelime bir duygudan sonra gelirse cümlemin duygusu tam tersine çevrilir ve ona göre puanlandırma yapılır. İkinci kural olarak karşıt bağlaç kullanıldığında cümle olumsuza çevrilir ve puan ağır-

lığı eksi olur. Üçüncü kural ise derece zarflarına farklı ağırlıklar verilmesi üzerinedir. Bu kuralların birçok olumlu ve olumsuz yanları olmaktadır. Bu çalışmada duyarlılık sözlüğü ve TF-IDF yöntemini birleştiren yeni bir yöntem tasarlanmıştır. Tüm duygu kelimelerinin ağırlıkları E olarak değerlendirilir ve bir metnin toplam ağırlığı 1 olarak sınırlandırılır. Daha sonra ağırlık ikiye bölünür ve tüm duygu kelimeleri a olarak adlandırılırken nötr kelimelere 1-a ifadesi TF-IDF değerleriyle orantılı olarak atanır. Sonuç olarak bu verilerle denklem elde edilir. Duygu analizi için Yu Hua'nın "Çiseleyen Yağmurda Çılgınlıklar" adlı romanı 16 bölüm şeklinde ayrıştırılarak veri olarak kullanılmıştır. Sonuçlar incelendiğinde toplamda 2079 cümle analiz edilmiştir. Metindeki verilerin duygu dağılımı incelendiğinde romanın daha çok olumsuz duygular içerdiği gözlemlenmiştir. Değerlendirme olarak kesinlik, geri çağırma ve f1 puanı hesaplanmıştır. Duygu sözlüğüne dayalı kurallar, TF-IDF ve bu çalışmada önerilen yöntemlerin doğruluk oranı karşılaştırıldığında en yüksek oranı önerilen yöntem karşılamıştır. Geri çağırma için yöntemler karşılaştırıldığında en yüksek oranı pozitif duygularda duygu sözlüğüne dayalı kurallar, nötr ve negatif duygularda ise önerilen yöntem karşılamıştır. F1 skoru karşılaştırılmasında üç durumda da önerilen yöntem en yüksek oranı vermiştir. Sonuca bakıldığında önerilen yöntem en iyi performansı göstermiştir.

Başarlan ve Kayaalp [5] yapmış oldukları çalışmada, TripAdvisor ve Rotten Tomatoes gibi web sitelerindeki açık kullanıcı geri bildirimlerine duygu analizi uyguladılar. Word2Vec ve TF-IDF yöntemleri kullanılarak dört makine öğrenme ve iki topluluk öğrenme yöntemiyle sonuçlar elde edilir. Topluluk öğrenme, özellikle çoğunluk oylaması, tekli öğrenme yöntemlerinden daha etkili sonuçlar gösterir. Eğitim-test ayrımları %80-%20 ve %70-%30 olarak iki şekilde yapılmıştır. Metin ön işleme adımları arasında yorum temizleme, özel karakterleri çıkarma, küçük harfe dönüştürme ve stemming yer almaktadır. LR, SVM, NB ve KNN sınıflandırıcıları kullanılarak gerçekleştirilen deneylerde, scikit-learn kütüphanesi Python ile

uygulanmıştır. Bu çalışma, topluluk öğrenme yöntemlerinin duyarlılık sınıflandırma sürecine önemli katkı sağladığını göstermektedir.

Karayığit ve arkadaşlarının [19] yapmış oldukları çalışmanın amacı, öğrencilerin sistem hakkındaki düşüncelerini öğrenmek için sistem hakkında toplanan Türkçe tweetlerin duygu analizini yapmaktır. Türkçe dilinde duygu analizi için makine öğrenmesi yaklaşımlarının daha iyi performans gerçekleştirdiği yapılan araştırmalarla ortaya konulmuştur. Bu nedenle bu çalışmada makine öğrenimi tabanlı yöntemler tercih edilmiştir. Twitter aracılığıyla konu ile ilgili hashtag kullanılarak 63699 adet tweet toplanmıştır. Veri ön işleme dört adıma ayrılmış olup bunlar; temizleme, normalizasyon, tokenizasyon ve durak kelimeleri kaldırma adımlarıdır. Temizleme kısmında gereksiz kelimeler, bağlantılar veri kümesinden çıkarılmıştır. Yabancı dil kullanılan tweetler “Language Detection API” ile tespit edilip aynı şekilde veri kümesinden çıkarılmıştır. Geriye 4652 adet tweet kalmıştır. Normalleştirme kısmında ise noktalama işaretleri kaldırılmış ve tüm harfler küçük harfe dönüştürülmüştür. Tokenizasyon kısmında kalan veriyi anlamlı parçalara bölme işlemi yapılmıştır. Durak kelimeler ise metinde hiçbir anlam içermeyen kelimeler ve ifadelerdir. Son adımda durak kelimeler çıkarılarak kalan metin daha anlamlı hale gelmiştir. Duygu analizinde üç ayrı duygu kullanılmıştır; olumlu, olumsuz ve nötr. Vektör uzayı modeli olarak ise Bag of Words ve TF-IDF kullanılmıştır. Duygu sınıflandırması için bu çalışmada Destek Vektör Makinesi, Lojistik Regresyon, K-En Yakın Komşu ve Yapay Sinir Ağları kullanılmıştır. Veri seti 1075 negatif, 3345 nötr ve 232 pozitif veriden oluşmaktadır. Veri setinde açık bir şekilde görülen dengesizlik vardır. Bu sebeple karşılaştırma için F1 skoru kullanılmıştır. Sonuçlar incelendiğinde Lojistik Regresyon sınıflandırıcının TF-IDF ve BoW vektör uzaylarını kullanarak diğer makine öğrenimi yöntemlerine göre daha iyi sonuç verdiği görülmüştür. Detaylı incelemede SVM, ANN

ve kNN yöntemlerinin BoW vektör uzayı modeli kullanılan çalışmada, LR yönteminin ise TF-IDF modeli kullanan çalışmada çok daha iyi sonuç verdiği gözlemlenmiştir.

Aydın ve arkadaşları [3] yapmış oldukları çalışmada, duygu analizi ve fikir madenciliği arasında ilişkiyi açıklayarak bunlar üzerinde bir inceleme yapmayı amaçlamışlardır. Ayrıca bu çalışmada Türkçe'nin diğer dillerden daha farklı olmasına ve bir kelime ile bir cümle kurulabilmesine dikkat çekilmiş, duygu analizi yaparken başka bir dilin modellerinin kullanılamayacağı fakat duygu analizinde kullanılan yöntemlerin kullanılabileceği vurgulanmıştır. Duygu analizi ve fikir madenciliği incelendiğinde fikir madenciliğinin akademik alanda, duygu analizinin ise endüstride kullanıldığı görülmektedir. Farklılıklar olsa dahi iki alanında birlikte çalıştığı gözlemlenmiştir. Sonuçlar kısmında Türkçe duygu analizi yapmak için veri kümesi bulunmaması gibi zorluklar yaşandığına, bu zorlukların sosyal medyadan veri elde edilmesi ile aşılabileceğine değinilmiştir. Aynı zamanda bu konu ile ilgili yapılan projelerin yetersiz olması gereken bütçenin sağlanması ile aşılabileceği belirtilmiştir. Eğitim setinin kategori olarak düzgün ayarlanmasının analiz üzerinde doğrudan etkili olduğu söylenmiştir.

Salur ve Aydın [31] yapmış oldukları çalışmada, Türkçe tweetler için yeni bir duygu sınıflandırma modeli tasarlamıştır. Veri ön işlemede silinen karakterlerden, emojiler gibi sözcüklerden özellik çıkarma ve diğer özelliklerle birleştirilmesine dayalı bir çalışmadır. Veri kümesinde 6887 adet pozitif ve 7890 adet negatif tweet bulunmaktadır. Tweetler anlamlı veya anlamsız birçok karakter, kelime içermektedir. Bu kelimelerin daha anlamlı olabilmesi için veri ön işleme yapılmıştır. Veri ön işlemede URL bilgisi, fazla boşluklar, noktalama işaretleri, kullanıcı adı, anlamsız kelimeler, rakamlar ve tek karakterler silinmiş karakter tekrarı içerdiği için anlamsız olan kelimeler düzeltilmiştir. Ayrıca daha önce yapılan çalışmalarda Türkçe tweetlerin analizinde kelime gövdeleme işlemi, duygu analizin performansına katkı sağlamadığı için bu çalışmada kullanılmadığına değinilmiştir. Kalan veriler FastText

kullanılarak metin temsili oluşturulmuş ve bu veri kümesinden LSTM, BiLSTM ve GRU kullanılarak derin özellik çıkarımı yapılmıştır. Veri ön işleme kısmında silinen içeriklerin aslında duygu belirttiği ve Twitter'a özgü ifadeler olduğu görülmüştür. Bu içeriklerden 12 adet elle özellik çıkarımı yapılmıştır. Bu özellikler, sözdizimsel olarak; toplam karakter sayısı, büyük harf sayısı, küçük harf sayısı, rakam sayısı, noktalama işareti sayısı ve URL sayısı olarak toplam 6 tane, Twitter'a özgü olarak; Bahsetme (mention) sayısı ve Hashtag sayısı olarak toplam 2 tane ve anlamsal olarak; pozitif emoji sayısı, negatif emoji sayısı, pozitif ünlem sayısı, negatif ünlem sayısı olarak toplam 4 tane özellikten oluşmaktadır. Elle çıkarılan özellikler LSTM, BiLSTM ve GRU kullanılarak derin özellikler çıkarılmıştır. Daha sonra FastText kullanılarak yapılan özellik çıkarımı ile elle yapılan özellik çıkarımı birleştirilerek duygu sınıflandırma katmanına iletilmiştir. Bu çalışmada veriler eğitim için %90 ve test işlemi için %10 olarak ayrılmıştır. Modelin başarısını değerlendirmek için karmaşıklık matrisi kullanılmıştır. Karmaşıklık matrisinden elde edilen değerlerle doğruluk, kesinlik, duyarlılık ve F1 skoru hesaplanmıştır. Derin özellik çıkarma modelinde doğruluk oranları incelendiğinde BiLSTM'in daha yüksek doğruluk verdiği gözlemlenmiştir. Genel sonuçlarda en yüksek doğruluk oranı %75.71 oran ile elle özellik çıkarma ve BiLSTM'in birleşiminden oluşan modelde gözlemlenmiştir. Çıkan sonuçlar incelendiğinde en yüksek sonuçların özellik birleştirme modellerinde olduğu görülmektedir. Bu çalışma daha önce yapılan çalışmalar ile karşılaştırıldığında önerilen modelin daha iyi performans gösterdiği gözlemlenmiştir.

Tan ve arkadaşları [37] yapmış oldukları çalışmada, duygu analizi sırasında alaycılık tespitini artırmaya yönelik bir çerçeve sunmuşlardır. Alaycı ifadelerin duygu sınıflandırmasını olumsuz etkilediği belirtilmiş ve bu sorunu çözmek adına çoklu görev öğrenimini içeren bir derin sinir ağı kullanılmıştır. Çerçeve, duygu sınıflandırması ve alaycılık sınıflandırması görevlerini aynı anda gerçekleştirmek üzere Çift Yönlü LSTM ağını eğitmeyi

içermektedir. Çalışma, bu yöntemin diğer modellere göre daha iyi performans sergilediğini göstermektedir. Veri kümesi olarak Kaggle'dan elde edilen duyarlılık ve alaycılık veri kümeleri kullanılmıştır. Her iki veri kümesi için aynı doğal dil işleme teknikleri ve ön işleme yöntemleri uygulanmıştır. Çerçeve, özellikle paylaşılan bir katman kullanarak aşırı uyum riskini azaltmayı amaçlayarak duygu analizi performansını artırmayı hedeflemektedir. Önerilen çerçeve, duyarlılık sınıflandırması için %91, alaycılık sınıflandırması için %92 F1 puanları elde etmiştir. Bağımsız Bi-LSTM modeline kıyasla, çerçeve duyarlılık ve alaycılık sınıflandırmalarında sırasıyla %3 ve %1 iyileşme sağlamıştır. Çerçeve, çoklu görev öğrenimi kullanarak eğitildiğinden hem eğitim süresini hem de hesaplama gücünü daha verimli bir şekilde kullanmaktadır.

Tsai ve Huang [38] yapmış oldukları çalışmada, evcil hayvanların duygu analizini yapay zeka sistemlerinde derin öğrenme teknolojileriyle gerçekleştirmeyi amaçlamıştır. İnsan duygu analizi çerçevesini evcil hayvanlar için uyarlayarak görüntü ve ses özelliklerini birleştirerek duygu analizi yapılmıştır. Evcil hayvanların yüz kaslarının sınırlamaları nedeniyle duruşları, ses özellikleri ise spektrogram kullanılarak değerlendirilmiştir. Nesne etiketlerini tespit etmek ve tanımlamak için Mask R-CNN kullanılarak derin öğrenme teknolojileriyle evcil hayvanların duygu analizi gerçekleştirilmiştir. Kullanılan teknolojiler arasında Logitech Webcam C925 kamera, gömülü sistemlerde çekirdek bilgi işlem platformu, Python programlama dili ve Tensorflow derin öğrenme kütüphanesi bulunmaktadır. Ortalama yürütme süresi 1,32 dakika olan önerilen yöntemin doğruluğu %85,71'dir. Bu yöntemin, temassız bir şekilde evcil hayvan duygu tanımlamasında başarılı bir doğruluk oranına sahip olduğu ve sahibine bilgi sağladığı vurgulanmıştır.

Chen ve arkadaşları [9] yapmış oldukları çalışmada, askeri alandaki duygu analizi için özel olarak geliştirilen MILSentic adlı duygu sözlüğünün performansının değerlendirmişlerdir.

Yapılan deneylerde, mevcut duygu sözlükleri ile MILSentic'in kombinasyonları kullanılarak gerçekleştirilen analizlerde, MILSentic'in eklenmesinin kutupluluk tahmininde %1,5 ve %1,4 daha yüksek doğruluk ve F1-ölçümü sağladığı belirlenmiştir. Ayrıca, çalışma, LSTM ve Bi-LSTM modelleri kullanılarak gerçekleştirilen parametre kalibrasyonunu içermektedir. Bu bağlamda, ağ katmanları ve aktivasyon fonksiyonları üzerinde yapılan ayarlamalarda, doğruluk ve F1-ölçümü değerlerindeki değişiklikler gözlemlenmiştir. Bi-LSTM modeli, özellikle Tanh aktivasyon fonksiyonu ve belirli bir ağ katmanı sayısı ile birlikte kullanıldığında en iyi performansı sergilemiştir. Bu çalışma, askeri duygu analizi için özel veri kaynaklarının etkili bir şekilde kullanılmasının, duygu sözlüklerinin geliştirilmesinin ve derin öğrenme modellerinin parametre ayarlarının performans artışına nasıl katkı sağlayabileceğini detaylı bir şekilde ele almaktadır.

Proje tasarımı dersi kapsamında incelenen çalışmaların genel özetlerinin yanında karşılaştırma tablosu da hazırlanmıştır. Karşılaştırma tabloları Çizelge 1-3'de verilmektedir.

Çizelge 1: Çalışmaların Karşılaştırılması

Çalışma	Yöntem	Sonuç	Çalışılan Konu
Rawad vd. [28]	BNB	%81	Aşı ile atılan tweet verileri incelenmiştir.
	SVC	%97	
	LR	%95	
Demir vd. [10]	DistilBERT, RoBERT	%80, %80,	Türkçe haber metinleri işlenmiştir.
	ALBERT, NB	%77, %71	
	SVC, RF	%68, %68	
Öge vd. [24]	LR	%87	IMDB film yorumları üzerinde duygu analizi yapılmıştır.
Fu vd. [12]	LSTM	%78.5	Belirli duygu analizi veri kümeleri üzerinde model başarımları karşılaştırılmıştır.
	LE-LSTM	%80.8	
Rumeli vd. [30]	NB SVM	%73.2 %73.4	Türkçe metinler için bir duygu analizi modeli geliştirilmiştir.
	RF k-NN	%73.3 %73.8	
Wang vd. [39]	CNN Bİ-LSTM	%89.9 %90.6	Geleneksel kelime gösterimine duygu bilgisi ekleyememe sorununu çözmek amaçlanmıştır.
	Bİ-GRU	%91.1	
Hassan vd. [14]	kNN DT	%59.7 %61.5	Tweetler kullanılarak COVID-19 salgınının tespiti araştırılmıştır.
	SVM NB	%80.9 %51.6	
Başarslan ve Kayaalp [5]	NM kNN	%82.5 %81.2	Açık kullanıcı geri bildirimlerine duygu analizi uygulanmıştır.
	LR SVM	%83.2 %84.6	

Çizelge 2: Çalışmaların Karşılaştırılması

Çalışma	Yöntem	Sonuç	Çalışılan Konu
Poornima ve vd. [26]	MNB	%83.54 %85.69	Twitter verilerini kullanılarak cümle sınıflandırılmasında performans karşılaştırması yapılmıştır.
	SVM		
	LR		
Zhang ve Zheng [41]	SVM	%88.54	Çince metinlerde duygu analizini ele alınmıştır.
	ELM with kernels	%88.74	
Sharma vd. [35]	CNN	%93.5	Çok terimli makine öğrenimi yaklaşımlarının duygu analizindeki performansları karşılaştırmıştır.
	LSTM	%77.5	
Xu ve Song [40]	CNN LSTM	%97.9 %97.68	Derin öğrenme ve geleneksel yöntemler ile duygu analizi yapılmıştır.
	GRU	%97.89	
	Bert+BiLSTM	%97.37	
	Bert + CNN	98.34	
Aydın vd. [3]	SVM LR	%73.5 %75.32	Duygu analizi ve fikir madenciliği arasında ilişkiyi açıklamışlardır.
	kNN	%62.03	
	ANN	%74.11	
Salur ve Aydın [31]	SVM	%65.2	Türkçe tweetler için yeni bir duygu sınıflandırma modeli tasarlanmıştır.
	MNB	%66.6	
	Bi-BiLSTM	%75.71	
Jagadeesan vd. [16]	RF LR	%95 %94	Makine öğrenimi ile duygu analizi yapılmıştır.
	DT SVM	%93 %95	
Aytuğ vd. [4]	NB	%89.10	Duygu analizinde psikodilbilimsel bir yaklaşım benimsenmiştir.

Çizelge 3: Çalışmaların Karşılaştırılması

Çalışma	Yöntem	Sonuç	Çalışılan Konu
Singh ve vd. [36]	RF	%77.90	TF-IDF ve makine öğrenimi algoritmaları ile duygu analizi yapılmıştır.
	SVM	%83.76	
Saraswat vd. [32]	ANN	%84	Ses ile duygu analizi yapılmıştır.
Pandya vd. [25]	SVM NB	%76.67 %75.67	Tweetler üzerinde duygu analizi yapmak hedeflenmiştir.
	Bi-LSTM	%82.13	
	RNN LSTM	%78.36 %80.83	
Kemaloğlu vd. [40]	MLR	%83.07	Facebook, Twitter, Instagram, YouTube ve Rss verilerini kulla- narak duygu analizi yapılmıştır.
	RF	%84.24	
	LSTM	%84.46	
Satrya vd. [34]	SVM	%96.64	Toplumsal dijital varlıklara yönelik tutumlarını anlamak amaçlanmıştır.
Sarkar ve Bhowmick [33]	SVM	%45	Bengalce tweetler üzerine araştırma yapmıştır.
	NB	%44.2	
Hammad ve Anwar [13]	SVM NB	%71.3 %61.8	Sindhi dilinde makine öğrenimiyle duygu analizi gerçekleştirilmiştir.
	DT kNN	%65.1 %66.1	
Jagadeesan vd. [16]	RF LR	%95 %94	Makine öğrenimi ile duygu analizi yapılmıştır.
	DT SVM	%93 %95	
Jayakody ve vd. [17]	CNN	%90.90	Ürün inceleme yorumları üzerinde duygu analizi yapılmıştır.
	NB	%57.90	
	SVM	%67.7	

BÖLÜM: İİ

MATERYAL

ÇALIŞMADA KULLANILACAK VERİ SETLERİ

Çevrimiçi sosyal medya ve inceleme platformlarının artan kullanımı, çeşitli görüşler içeren büyük miktarda verinin kaydedilmesine olanak tanımaktadır. Bu veri, duygu analizi ile incelendiğinde, ürün incelemeleri, blog yorumları ve forum tartışmaları gibi metinlerdeki duyguların anlaşılmasına imkan sağlar. Duygu analizi, sadece bireylerin ürün deneyimlerini değil, aynı zamanda siyasi atmosferin duygusal tonunu (örneğin, politikalarla ilgili kamu duygularının analizi), finansal piyasaların duygusal durumunu (örneğin, pazarın duygularının analizi) ve pazarlama stratejilerinin geliştirilmesinde kullanılabilecek ürün araştırması ve marka yönetimi gibi çeşitli alanlarda geniş uygulamalara sahiptir. Bu analizler, karar verme süreçlerini desteklemede önemli bir rol oynayarak, çeşitli sektörlerde stratejik bilgilerin elde edilmesine katkı sağlar. Bu çalışmada duygu analizi için 2 veri kümesi kullanılacaktır. Bunlardan ilki IMDB film yorumları veri kümesidir [1]. Diğeri ise Amazon kullanıcı yorumlarından oluşmaktadır [2].

3.1 *IMDB Film Yorumları*

IMDB, kullanıcıların film ve televizyon içerikleri hakkında yorumlar yapabildiği, derecelendirebildiği bir topluluk platformu olarak da bilinir. Kullanıcılar, izledikleri filmleri ve dizileri puanlayabilir, yorumlar yazabilir ve bu platform aracılığıyla diğer kullanıcılarla etkileşimde bulunabilirler. Yaklaşık 25.000 tane IMDB film yorumlarından oluşan verisetimiz bulunmaktadır. Bu veriseti üzerinde duygu analizi yapacağız. Duygu analizi, pazar araştırması ve tüketici tercihleri konusunda da büyük bir katkı sağlar. Film izleyicilerinin beklentilerini ve taleplerini belirlemek, yapımcılara gelecek projeleri planlama ve pazarlama stratejilerini oluşturma konusunda rehberlik eder. Pozitif ve negatif yönlerin belirlenmesi, film yapımcılarına eleştiriye dayalı iyileştirmeler yapma ve izleyici kitlesini daha etkili bir şekilde çekme şansı verir. İzleyicilerin filmler hakkındaki duygusal tepkilerini anlamak, etkili bir tanıtım kampanyası oluşturmak ve hedef kitleleri daha etkili bir şekilde çekmek için kritik bir rol oynar. Bu nedenle, IMDB film yorumları üzerinde yapılan duygu analizi, film endüstrisindeki paydaşlara film deneyimlerini daha derinlemesine anlama ve iyileştirme fırsatı sunar.

3.2 *Amazon Kullanıcı Yorumları*

Amazon, dünyanın en büyük e-ticaret platformlarından biridir ve kullanıcıların geniş bir ürün yelpazesindeki ürünleri değerlendikleri bir forum sağlamaktadır. Amazon üzerindeki ürün yorumları, potansiyel alıcılar için önemli bir referans kaynağıdır. Bu yorumlar, müşterilerin ürün deneyimlerini paylaşmalarına ve diğer kullanıcılara rehberlik etmelerine olanak tanır. Amazon kullanıcıların yaptığı yaklaşık 50.000 yorumdan oluşan bir veriseti üzerinde duygu

analizi yapacađız. Amazon yorumlarından çıkarılan duygu analizi, pazar trendleri ve talepler hakkında önemli içgörüler sunabilir. İşletmeler, bu analizlerle talep değışikliklerini öngörebilir ve stratejilerini pazar dinamiklerine göre ayarlayabilirler. Bu nedenle, Amazon'daki yorumlar üzerinde yapılan duygu analizi çalışmaları, işletmelere müşteri ilişkilerini güçlendirmek, ürün ve hizmet kalitesini artırmak ve rekabet avantajı elde etmek için değerli bir araç sunar.

KÜTÜPHANELER

Projemizde kullanacağımız kütüphanelere yer verilmektedir.

4.1 *NLTK*

Doğal Dil İşleme uygulamalarında, NLTK'nin duygu analizi araçları metin verilerini anlamak ve bu veriler üzerindeki duygu durumlarını sayısal bir formda ifade etmek için kullanılır. Bu araçlar, genellikle sosyal medya analizi, müşteri geribildirimini değerlendirmesi, ürün incelemeleri analizi, kampanya etkinliği değerlendirmesi ve halkla ilişkiler yönetimi gibi birçok uygulama alanında kullanılır.

4.2 *Zemberek*

Zemberek kütüphanesi, NLP görevleri için geliştirilmiş bir Java kütüphanesidir. Duygu analizi gibi metin madenciliği görevlerinde kullanılabilecek özelliklere sahiptir. Kütüphane, Türkçe metinler üzerinde dilbilgisel analizler yapma, kelime köklerini bulma, cümle ayrıştırma ve benzeri işlemleri gerçekleştirmek üzere tasarlanmıştır.

4.3 *TensorFlow*

TensorFlow, duygu analizi gibi metin verileri üzerinde çalışan uygulamalarda kullanılan açık kaynaklı bir makine öğrenimi kütüphanesidir. Veri hazırlığından başlayarak, metin verilerini sayısal formata dönüştürmek, model oluşturmak, eğitmek ve değerlendirmek aşamalarında TensorFlow'un sunduğu araçlar kullanılarak etkili duygu analizi modelleri geliştirilebilir. Eğitilen model, ardından uygulama alanına entegre edilerek gerçek zamanlı tahminler yapabilir. TensorFlow'un esnek ve güçlü yapısı, derin öğrenme alanında duygu analizi gibi çeşitli uygulamalarda başarıyla kullanılmasına imkân tanır.

4.4 *Spacy*

Spacy, NLP görevlerini gerçekleştirmek için kullanılan açık kaynaklı bir Python kütüphanesidir. Bu kütüphane, metin verileri üzerinde dilbilgisel analiz, metin madenciliği ve benzeri NLP görevlerini gerçekleştirmek için tasarlanmıştır.

Projede özel karakterler, hashtag'ler, noktalama işaretleri, tweeter tanıtıcısı, bağlantılar, ekstra satır sonları ve önemli bir ağırlığa sahip olmayan metin gibi metnin ilgisiz kısımlarını kaldırmak için Spacy kütüphanesini kullanılabilir.

4.5 *Numpy*

NumPy, Python dilinde bilimsel hesaplamalar için kullanılan güçlü bir kütüphanedir. NumPy'nin temelini çok boyutlu diziler oluşturur ve bu diziler üzerinde hızlı ve etkili matematiksel işlemler gerçekleştirilmesini sağlar. Duygu analizi gibi işlemler için özellikle

veri manipölasyonu ve matematiksel operasyonlar gerektiğinde NumPy kullanılabilir. Örneğin, modelin ağırlıklarını güncellemek veya özellik matriksini oluşturmak için NumPy kullanılabilir.

4.6 *Pandas*

Pandas, Python dilinde oldukça popüler olan bir veri analizi kütüphanesidir. Duygu analizi projelerinde, metin verileri üzerinde çalışma aşamalarında genellikle pandas kullanılır. İlk adım genellikle veri setini okumak ve incelemektir. Pandas ile veri okuma işlemi oldukça basit bir şekilde gerçekleştirilebilir. Daha sonra, metin verilerini temizleme ve ön işleme aşamasına geçilir. Pandas ile metin sütunları üzerinde yapılabilecek işlemler arasında metinleri küçük harfe çevirme, noktalama işaretlerini kaldırma, durak kelimeleri (stop-words) temizleme gibi işlemler bulunur. Duygu analizi genellikle etiketlenmiş veri gerektirir. Pandas ile etiketleme işlemleri kolayca gerçekleştirilir. Son olarak, pandas ile istatistiksel analizler yapılabilir. Bu analizler, veri setinizin içeriği hakkında daha fazla bilgi edinmenize ve modelinizi daha iyi anlamanıza yardımcı olabilir.

4.7 *Keras*

Keras, Python dilinde popüler bir derin öğrenme kütüphanesi olup, duygu analizi gibi metin tabanlı görevlerde etkili bir şekilde kullanılabilir. Proje adımları genellikle etiketlenmiş bir veri seti elde etme, veriyi eğitim ve test setlerine ayırma, metin verilerini ön işleme ve sayısallaştırma içerir. Keras ile model oluşturma süreci basittir; Sequential model kullanılarak istenen katmanlar sıralı olarak eklenir ve derleme adımında kayıp fonksiyonu, optimize edici

ve performans metrikleri belirlenir. Eğitim aşamasında, model eğitim verileri ile beslenir ve genelleme yeteneği test verileri üzerinde değerlendirilir. Eğitilen model, yeni metin verileri üzerinde duygu analizi tahminleri yapmak için kullanılabilir. Keras, kullanıcı dostu bir çözüm sunar ve derin öğrenme modellerini hızlı bir şekilde oluşturup eğitmek için etkili bir araçtır. Özellikle metin verileri üzerinde çalışırken, Keras'ın esnekliği ve kullanım kolaylığı, duygu analizi projelerinde avantaj sağlar.

4.8 *scikit-learn*

Scikit-learn kütüphanesi, Python dilinde yaygın olarak kullanılan bir makine öğrenimi kütüphanesidir ve duygu analizi gibi metin sınıflandırma görevlerinde etkili bir şekilde kullanılabilir. Bu kütüphane, veri hazırlığından başlayarak model eğitime kadar bir dizi işlemin gerçekleştirilmesine imkan tanır.

4.9 *e1071*

e1071 kütüphanesi, R programlama dilinde kullanılan güçlü bir pakettir ve temel olarak SVM ile diğer istatistiksel modelleri içerir. Bu paket, sınıflandırma ve regresyon görevlerinde etkili olan SVM'nin yanı sıra k-NN algoritması gibi modelleri uygulamak için tasarlanmıştır.

Özellikle, e1071 paketi içinde bulunan `svm()` fonksiyonu, destek vektör sınıflandırıcısını ve destek vektör regresyonunu uygulamak için kullanılır. Bu fonksiyon, iki veya daha fazla sınıfı olan sınıflandırma görevlerinden, sayısal değerlerle ilişkili regresyon analizlerine kadar geniş bir uygulama yelpazesi sunar.

4.10 *Twint*

Twint kütüphanesi, Twitter verilerini çekmek ve analiz etmek için kullanılan etkili bir Python aracıdır. Twitter'ın resmi API'sine gerek duymadan, açık profillere erişerek tweetleri ve kullanıcı bilgilerini çekme yeteneği sunar. Bu kütüphane sayesinde belirli bir kullanıcının tweetlerini, takipçi sayısını, takip ettiği kişileri veya belirli bir konu etiketi altındaki tweetleri çekmek mümkündür. Twint, Twitter verilerini çekme sürecini kolaylaştırarak özelleştirilmiş analizler yapmak isteyen kullanıcılara geniş bir esneklik sunar.

BÖLÜM: İİİ

YÖNTEM

VERİLERİN HAZIRLANMASI

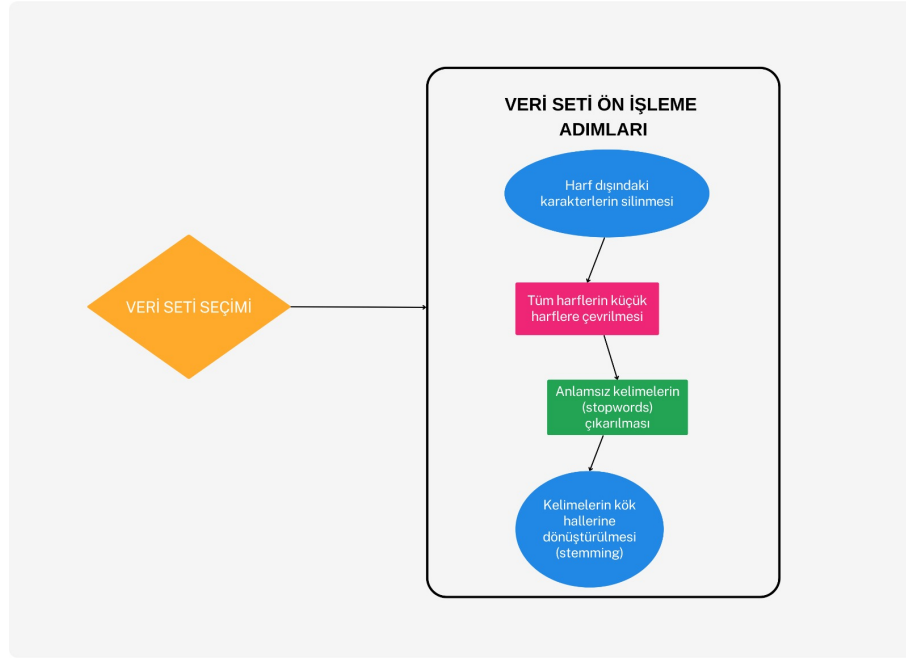
Bulduğumuz verileri kullanabilmek için bazı adımlar vardır. Bu adımlar verinin daha anlamlı, tutarlı ve kullanılabilir hale gelmesini sağlar.

5.1 Veri Önışleme

Veriyi analiz yapmak veya modele hazırlamak için gerçeklerřtirilen adımlara veri önışleme denir. Bu adımlar harf dıřındaki karakterlerin silinmesi, tüm harflerin küçük harfe dönüřtürölmesi, durak kelimelerin (stopwords) çıkarılması ve kelimelerin kök haline dönüřtürölmesidir. Bu adımlardan sonra makine veriyi anlamaya daha yakındır.

5.2 Metin Temsil Yöntemleri

Metin temsili, NLP ve metin madenciliğı alanlarında metin verilerini sayısal formatta ifade etme sürecini ifade eder. Metin temsili, metin verilerini sayısal bir řekle dönüřtürerek, bilgisayar algoritmalarının bu verileri anlaması ve işlemleri için uygun bir form sağlar. Bu süreç, metin verilerinin içerdığı anlamı çıkarmak, benzerlik ve uzaklık ölçümleri yapmak,



Şekil 1: Veri Setinin Temizlenmesi için Uygulanan Adımlar

duygu analizi uygulamak gibi çeşitli uygulama alanlarında önemli bir rol oynar. Ön işleme adımları şekil 1’de adım adım gösterilmiştir.

5.2.1 Terim Sıklığı-Ters Belge Frekansı (TF-IDF)

TF-IDF, metin belgelerindeki kelimelerin önemini ve belgeler arasında benzersizlik düzeyini ölçen bir sayısal değerdir. TF, bir belgede kelimenin kaç kez geçtiğini hesaplar. IDF ise kelimenin belge içindeki özgünlüğüne bakar. Yüksek IDF değeri kelimenin özgün olduğu anlamına gelir. Kelime belgede çok yerde geçmişse IDF değeri düşer. TF-IDF değeri TF ile IDF değerlerinin çarpımı ile hesaplanır. Yüksek TF-IDF değerleri, belgede sıkça geçen ancak aynı zamanda belge koleksiyonu içinde özgün olan terimleri vurgular.

5.2.2 Kelime Çantası (Bag Of Words)

Bag of Words yöntemi ilk adımda, belge koleksiyonundaki farklı kelimelerden oluşan bir kelime dağarcığı oluşturulur. Her kelime bir indekse atanır. Ardından, her belge, kelime dağarcığına göre bir vektörle temsil edilir. Bu vektör, belgedeki her kelimenin frekansını içerir. Şekil 2’de örnek olarak gösterilmiştir.

	Feyza	pizza	yemeyi	sevdiği	için	sipariş	etti	hamburger	Aleyna	yedi	Hasan	Dilara
Feyza pizza yemeyi sevdiği için pizza sipariş etti	1	1	1	1	1	1	1	0	0	0	0	0
Aleyna hamburger yedi	0	0	0	0	0	0	0	1	1	1	0	0
Hasan pizza sipariş etti	0	1	0	0	0	1	1	0	0	0	1	0
Dilara hamburger sevdiği için ham- burger yedi	0	0	0	1	1	0	0	1	0	1	0	1

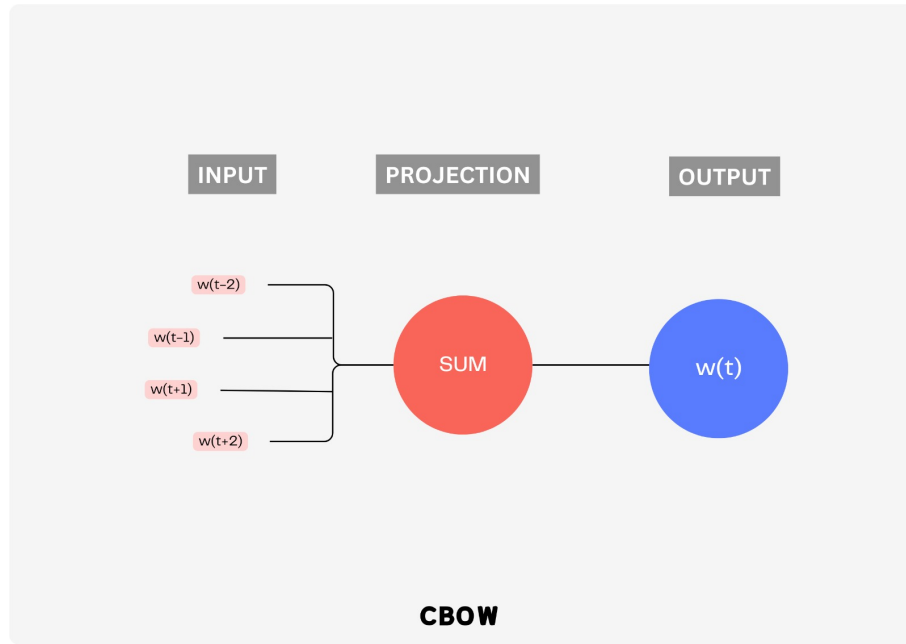
Şekil 2: Bag Of Words Yöntemi

5.2.3 Word2Vec

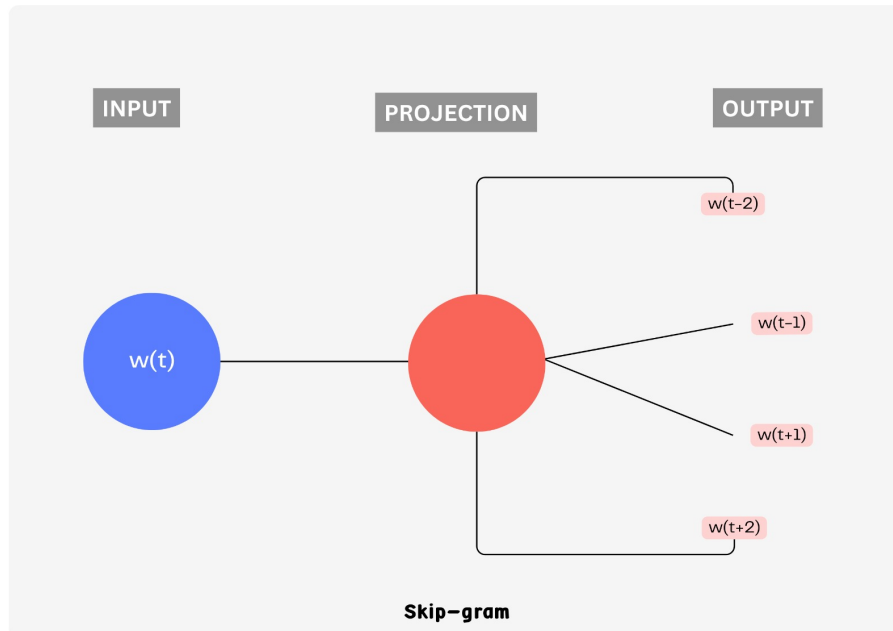
Word2vec, genellikle büyük metin verilerinden öğrenme işlemi yaparak kelimeler arasındaki ilişkileri öğrenir. Bu model, bir kelimenin çevresindeki bağlamı analiz eder ve bir kelimenin benzer bağlamdaki diğer kelimelerle aynı veya benzer vektör uzayında olmasını sağlar. CBOW ve Skip-gram modellerini kullanır.

CBOW modeli, bir kelimenin bağlamını kullanarak belirli bir bağlamdaki bir kelimenin önceki ve sonraki kelimeleri tahmin etmeye çalışır. Tasarımı Şekil 3’te verilmiştir.

Skip-gram modeli, bir kelimenin verilen bağlamdaki önceki ve sonraki kelimeleri tahmin etmeye çalışır. Tasarımı Şekil 4’te verilmiştir.



Şekil 3: CBOW Modeli



Şekil 4: Skip-gram Modeli

SINIFLANDIRMA YÖNTEMLERİ

Sınıflandırma algoritmaları, metin verilerindeki duygu ifadelerini (olumlu, olumsuz, tarafsız) belirlemek için kullanılır. Algoritma seçimi, kullanılacak veri setinin özelliklerine, problem bağlamına ve performans gereksinimlerine bağlı olarak değişebilir.

6.1 *Naive Bayes (NB)*

Naive Bayes , sınıflandırma problemlerinde yaygın kullanılan bir makine öğrenimi algoritmasıdır. Bu algoritma Bayes Teoremine dayanır. Basit, etkili ve hızlı çalışan bir sınıflandırma yöntemi olarak bilinir. Naive Bayes, belirli bir metin belgesinin içindeki kelimeleri kullanarak belirli bir duygusal tonu tahmin etmek için kullanılabilir.

6.2 *Destek Vektör Makineleri (SVM)*

Destek Vektör Makineleri, özellikle sınıflandırma ve regresyon problemlerinde kullanılan güçlü bir makine öğrenimi algoritmasıdır. SVM, özellikle veri setinin karmaşıklığı ve yüksek boyutlu özelliklere sahip olduğu durumlarda etkili bir performans gösterir. SVM, bir

sınıflandırma probleminde iki sınıf arasında bir karar sınırı oluşturarak çalışır. Bu karar sınırı, sınıflar arasındaki ayrımı en iyi şekilde sağlamak amacıyla seçilir.

6.3 *Lojistik Regresyon (LR)*

Lojistik regresyon, istatistik ve makine öğrenimi alanlarında sınıflandırma problemlerini çözmek için kullanılan bir regresyon analiz yöntemidir. Logistik regresyonun temel amacı, bağımsız değişkenler (özellikler) ile bağımlı bir değişken (sınıf etiketi) arasındaki ilişkiyi modellemektir.

6.4 *Karar Ağaçları (DT)*

Karar Ağaçları, özellikle sınıflandırma ve regresyon problemlerini çözmek için kullanılan bir makine öğrenimi algoritmasıdır. Karar ağaçları, karar verme süreçlerini ağaç yapısı içinde temsil eder ve bu yapı üzerinden tahminler yapar. Her iç düğüm, bir özellik ile ilgili bir karar noktasını temsil ederken yaprak düğümleri ise sonuçları içerir.

6.5 *Rastgele Orman (RF)*

Rastgele Orman, karar ağaçları temel alarak çalışan ve birleşik (ensemble) bir makine öğrenimi algoritmasıdır. Bu algoritma, birçok karar ağacını eğitip bunların tahminlerini bir araya getirerek daha güçlü ve genelleyici bir model oluşturmayı amaçlar. Random Forest, ağaçların aşırı uydurmayı azaltarak ve daha iyi genelleme yetenekleri sağlayarak sınıflandırma ve regresyon problemleri için etkili bir çözüm sunar.

6.6 Derin Öğrenme Modelleri

Derin öğrenme, karmaşık yapıdaki verileri anlamak ve öğrenmek amacıyla tasarlanmış yapay sinir ağı modelleri içeren bir makine öğrenimi dalıdır. Derin öğrenme modelleri, genellikle çok katmanlı yapılara (derin sinir ağları) sahiptir ve büyük miktarda veriyi otomatik olarak öğrenerek karmaşık örüntüleri tespit etme yeteneğine sahiptir. Sınıflandırma problemleri için derin öğrenme modelleri, genellikle son katmanda bir aktivasyon fonksiyonu kullanarak çıkışı sınıflar arasında bir olasılık dağılımına dönüştürür.

6.6.1 Tekrarlayan Sinir Ağları (RNN)

Tekrarlayan Sinir Ağları, sıralı veri yapıları üzerinde etkili olan bir yapay sinir ağı türüdür ve özellikle metin, zaman serisi veya diğer sıralı veri türlerindeki bağımlılıkları modellemek için kullanılır. Duygu analizi gibi görevlerde RNN'ler, metin içindeki sıralı bağımlılıkları anlamak ve ifade edilen duygusal durumları tahmin etmek amacıyla kullanılabilir.

6.6.2 Yapay Sinir Ağları (Artificial Neural Networks - ANN)

Yapay Sinir Ağları (ANN), duygu analizi gibi sınıflandırma görevlerinde kullanılan güçlü bir makine öğrenimi modelidir. Duygu analizi, metin verilerinde ifade edilen duygusal durumları, genellikle olumlu, olumsuz veya nötr olarak sınıflandırmaya yönelik bir süreçtir. Bu görevde ANN'ler, metin verilerini sayılara dönüştürmek, öğrenmek ve duygusal durumları tahmin etmek amacıyla etiketli bir veri seti üzerinde eğitilir.

6.6.3 Evrişimli Sinir Ağları (CNN)

Evrişimli Sinir Ağları, genellikle görüntü işleme için tasarlanmış olsa da, metin tabanlı görevlerde de başarılı olabilir. Duygu analizi gibi sınıflandırma görevlerinde kullanıldığında, CNN metin verilerindeki önemli özellikleri belirleyerek duygu durumlarını sınıflandırır. Metin verileri önce metin gömme katmanında vektörlere dönüştürülür, ardından evrişim ve havuzlama katmanları kullanılarak özellikler çıkarılır. Daha sonra, düzleştirme ve yoğun katmanlar ile sınıflandırma gerçekleştirilir. Eğitim veri seti üzerinde model eğitilir ve test verisi üzerinde performansı değerlendirilir. CNN, metin verilerindeki önemli özellikleri anlama yeteneğiyle duygu analizi gibi metin tabanlı sınıflandırma görevlerinde etkili bir araçtır.

6.7 K-En Yakın Komşu (k-NN)

k-NN, makine öğrenimi algoritmalarından biridir. Temel prensibi, benzer özelliklere sahip olan veri noktalarının etiketlerini veya değerlerini kullanarak tahmin yapmaktır. Algoritma eğitim aşamasında, her bir veri noktasının özellikleri ve etiketleri ile öğrenir. Tahmin aşamasında, yeni bir gözlem için en yakın k sayıdaki komşusunu belirleyerek sınıflandırma veya regresyon yapar. Basit ve anlaşılabilir olmasına rağmen, büyük veri setlerinde performans sorunları yaşayabilir ve hiperparametre seçimine dikkat edilmesi gerekir.

DEĞERLENDİRME

Sınıflandırma problemlerinde kullanılan performans ölçütleri, bir modelin veya sınıflandırıcı algoritmanın çeşitli yönlerini değerlendirmek ve modelin sınıflandırma yeteneğini anlamak için kullanılan metriklerdir. Bu metrikler, sınıflandırma modellerinin gerçek dünya uygulamalarında ne kadar etkili olduğunu anlamak ve modelin güvenilirliğini belirlemek için önemli araçlardır.

7.1 Doğruluk (Accuracy)

Doğruluk, bir sınıflandırma modelinin doğru tahminlerin toplam tahminlere oranını ölçen bir performans metriğidir. Doğru sonuçların tüm sonuçlara oranı ile hesaplanmaktadır. Formülü 1’de verilmiştir.

$$Dogruluk = \frac{DogruTahminSayisi}{TumTahminlerinSayisi} \quad (1)$$

7.2 Duyarlılık (Recall)

Duyarlılık, sınıflandırma modellerinin performansını değerlendirmek için kullanılan bir ölçüdür ve aynı zamanda "duyarlılık" olarak da adlandırılır. Duyarlılık, gerçek pozitif (true positive) sayısının, toplam gerçek pozitifler ve yanlış negatifler (false negatives) toplamına bölünmesi ile hesaplanır. Formülü 2’de verilmiştir.

$$Recall = \frac{DogruPozitif}{DogruPozitif + YanlisNegatif} \quad (2)$$

Duyarlılık, özellikle bir sınıfın gerçek pozitiflerinin tüm pozitif örnekler içinde ne kadar başarılı bir şekilde yakalandığını ölçer. Recall değeri 0 ile 1 arasında değişir, 1’e daha yakın bir değer daha iyi bir performansı gösterir. Yüksek recall değeri, modelin pozitif örnekleri kaçırma olasılığının düşük olduğunu gösterir.

7.3 Hassasiyet (Precision)

Hassasiyet, sınıflandırma modellerinin performansını değerlendirmek için kullanılan bir ölçüdür. Hassasiyet, gerçek pozitif (true positive) sayısının, gerçek pozitifler ve yanlış pozitiflerin (false positives) toplamına bölünmesi ile hesaplanır. Formülü 3’te verilmiştir.

$$Precision = \frac{DogruPozitif}{DogruPozitif + YanlisPozitif} \quad (3)$$

Hassasiyet, pozitif olarak tahmin edilen örneklerin ne kadarının gerçekten pozitif olduğunu ölçer. Hassasiyet değeri 0 ile 1 arasında değişir, 1’e daha yakın bir değer daha iyi bir performansı gösterir. Yüksek hassasiyet, modelin pozitif tahminlerinin genellikle doğru olduğunu gösterir.

7.4 *F1 Skoru*

F1 Skoru, bir sınıflandırma modelinin hassasiyet (precision) ve duyarlılık (recall) değerlerini birleştirerek performansını ölçen bir metriktir. F1 Skoru, bu iki metriğin harmonik ortalaması olarak hesaplanır. Formülü 4'te verilmiştir.

$$F1Score = \frac{Hassasiyet * Duyarlilik}{Hassasiyet + Duyarlilik} \quad (4)$$

7.5 *Süre (Time)*

Sınıflandırma modelinin performansını değerlendirirken süre modelin hızlı ve etkili bir şekilde tahmin yapma yeteneğini ifade eder. İşlem süresi, modelin eğitimini gerçekleştirmesi ve yeni örnekleri sınıflandırması için geçen süreyi içerir.

BÖLÜM: İV

GELECEK ÇALIŞMALAR

GELECEK ÇALIŞMALAR

Bu proje, makine öğrenimi ve derin öğrenme yöntemlerini kullanarak duygu analizini konu almaktadır. Projede, duygu analizi üzerine yapılan çalışmalar detaylı bir şekilde incelendi. Bu kapsamda kullanılan teknikler, kütüphaneler ve algoritmalar araştırıldı. Proje kapsamında kullanılabilen iki adet veri seti belirlendi. Bu veri setleri, projenin gerçekleştirilmesinde temel veri kaynaklarını oluşturacaktır. Belirlenen veri setleri üzerinde farklı tekniklerle duygu analizi gerçekleştirilecek. Bu aşamada, araştırılan makine öğrenimi ve derin öğrenme yöntemleri kullanılarak duygu analizi yapılacaktır.

Proje sonuçlarına dayanarak kullanılan farklı tekniklerin duygu analizi performansları karşılaştırılacaktır. Bu karşılaştırma, hangi yöntemlerin daha etkili olduğunu belirlemeye yönelik önemli bir değerlendirme sağlayacaktır. Bu proje, duygu analizi alanında kullanılan yöntemlerin ve algoritmaların pratikteki performansını anlamak ve geliştirmek için değerli bir katkı sağlamayı hedeflemektedir.

Proje sürecinde gerçekleştirilecek görevleri, bu görevlere ayrılacak zamanları ve bu görevlerin ilerleme durumunu izlemek için kullanılan bir iş zaman planlaması yapılmıştır. Projenin şekil 5'teki iş zaman akışına göre ilerlemesi planlanmaktadır.

İŞ PAKETİ	Ekim	Kasım	Aralık	Ocak	Şubat	Mart	Nisan	Mayıs	Haziran
Proje konusunun belirlenmesi									
Literatür Özeti									
Veri seti bulunması									
Rapor yazımı/Sunum									
Verilerin hazırlanması									
Duygu analizi									
Sonuçların analizi									
Rapor yazımı/Sunum									

Şekil 5: Projenin iş zaman planlaması

KAYNAKÇA

- [1] IMDB Veri seti: <https://ai.stanford.edu/~amaas/data/sentiment/>.
- [2] Amazon Veri seti: https://cseweb.ucsd.edu/~jmcauley/datasets.html#amazon_reviews.
- [3] AYDIN, Z. E., OZTURK, Z. K., AND ÇİÇEK, Z. İ. E. Turkish sentiment analysis for open and distance education systems. *Turkish Online Journal of Distance Education* 22, 3 (2021), 124–138.
- [4] AYTUĞ, O. Sentiment analysis on twitter based on ensemble of psychological and linguistic feature sets. *Balkan Journal of Electrical and Computer Engineering* 6, 2 (2018), 69–77.
- [5] BAŞARSLAN, M. S., AND KAYAALP, F. Sentiment analysis with ensemble and machine learning methods in multi-domain datasets. *Turkish Journal of Engineering* 7, 2 (2023), 141–148.
- [6] BHASIN, A., AND DAS, S. Twitter sentiment analysis using machine learning and hadoop: A comparative study. 267–272.
- [7] CAN, U., AND ALATAS, B. Duygu analizi ve fikir madenciliği algoritmalarının incelenmesi. *International Journal of Pure and Applied Sciences* 3, 1 (2017), 75–111.

- [8] CHANDRA, Y., AND JANA, A. Sentiment analysis using machine learning and deep learning. 1–4.
- [9] CHEN, L.-C., LEE, C.-M., AND CHEN, M.-Y. Exploration of social media for sentiment analysis using deep learning. *Soft Computing* 24 (2020), 8187–8197.
- [10] DEMIR, E., AND BILGIN, M. Sentiment analysis from turkish news texts with bert-based language models and machine learning algorithms. 01–04.
- [11] DHARIWAL, N., AKUNURI, S. C., BANU, K. S., ET AL. Audio and text sentiment analysis of radio broadcasts. *IEEE Access* 11 (2023), 126900–126916.
- [12] FU, X., YANG, J., LI, J., FANG, M., AND WANG, H. Lexicon-enhanced lstm with attention for general sentiment analysis. *IEEE Access* 6 (2018), 71884–71891.
- [13] HAMMAD, M., AND ANWAR, H. Sentiment analysis of sindhi tweets dataset using supervised machine learning techniques. 1–6.
- [14] HASSAN, S. M., JAWAD, K., KHAN, M. A., KHAN, M. S., AHMAD, I., AND MOHSIN, K. Detecting covid-19 pandemic using sentiment analysis of tweets. *Artificial Intelligence Theory and Applications* 1, 2 (2021), 39–47.
- [15] HE, H., ZHOU, G., AND ZHAO, S. Exploring e-commerce product experience based on fusion sentiment analysis method. *IEEE Access* 10 (2022), 110248–110260.
- [16] JAGADEESAN, M., SARAVANAN, T., SELVARAJ, P., ALI, U. A., ARUNSIVARAJ, J., AND BALASUBRAMANIAN, S. Twitter sentiment analysis with machine learning. 681–686.
- [17] JAYAKODY, J., AND KUMARA, B. Sentiment analysis on product reviews on twitter using machine learning approaches. 1056–1061.

- [18] JOSHI, V., PATEL, S., AGARWAL, R., AND ARORA, H. Sentiments analysis using machine learning algorithms. 1425–1429.
- [19] KARAYİĞİT, H., ÇİĞDEM, A., AND AKDAĞLI, A. A review of turkish sentiment analysis and opinion mining. *Balkan Journal of Electrical and Computer Engineering* 6, 2 (2018), 94–98.
- [20] KEMALOĞLU, N., KÜÇÜKSİLLE, E., AND ÖZGÜNSÜR, M. Turkish sentiment analysis on social media. *Sakarya University Journal of Science* 25, 3 (2021), 629–638.
- [21] KIM, R. Y. Using online reviews for customer sentiment analysis. *IEEE Engineering Management Review* 49, 4 (2021), 162–168.
- [22] LI, Z., LI, R., AND JIN, G. Sentiment analysis of danmaku videos based on naïve bayes and sentiment dictionary. *Ieee Access* 8 (2020), 75073–75084.
- [23] LIU, H., CHEN, X., AND LIU, X. A study of the application of weight distributing method combining sentiment dictionary and tf-idf for text sentiment analysis. *IEEE Access* 10 (2022), 32280–32289.
- [24] ÖĞE, B. C., AND KAYAALP, F. Farklı sınıflandırma algoritmaları ve metin temsil yöntemlerinin duygu analizinde performans karşılaştırılması. *Düzce Üniversitesi Bilim ve Teknoloji Dergisi* 9, 6 (2021), 406–416.
- [25] PANDYA, V., SOMTHANKAR, A., SHRIVASTAVA, S. S., AND PATIL, M. Twitter sentiment analysis using machine learning and deep learning techniques. 1–5.
- [26] POORNIMA, A., AND PRIYA, K. S. A comparative sentiment analysis of sentence embedding using machine learning techniques. 493–496.

- [27] PORIA, S., HAZARIKA, D., MAJUMDER, N., AND MIHALCEA, R. Beneath the tip of the iceberg: Current challenges and new directions in sentiment analysis research. *IEEE Transactions on Affective Computing* (2020).
- [28] RAWAT, A., MAHESHWARI, H., KHANDUJA, M., KUMAR, R., MEMORIA, M., AND KUMAR, S. Sentiment analysis of covid19 vaccines tweets using nlp and machine learning classifiers. 225–230.
- [29] RIZK, Y. E., AND ASAL, W. M. Sentiment analysis using machine learning and deep learning models on movies reviews. 129–132.
- [30] RUMELLI, M., AKKUŞ, D., KART, Ö., AND ISIK, Z. Sentiment analysis in turkish text with machine learning algorithms. 1–5.
- [31] SALUR, M. U., AND AYDIN, İ. Türkçe tweetler için derin özellik çıkarımı tabanlı yeni bir duygu sınıflandırma modeli. *Fırat Üniversitesi Mühendislik Bilimleri Dergisi* 34, 1 (2022), 1–13.
- [32] SARASWAT, S., BHARDWAJ, S., VASHISTHA, S., AND KUMAR, R. Sentiment analysis of audio files using machine learning and textual classification of audio data. 1–5.
- [33] SARKAR, K., AND BHOWMICK, M. Sentiment polarity detection in bengali tweets using multinomial naïve bayes and support vector machines. 31–36.
- [34] SATRYA, R. N., PRATIWI, O. N., FA'RIFAH, R. Y., AND ABAWAJY, J. Cryptocurrency sentiment analysis on the twitter platform using support vector machine (svm) algorithm. 01–05.

- [35] SHARMA, S., PANDEY, A., KUMAR, V., OHDAR, D., PILLAI, A. R., AND MAHAJAN, M. Recent trends in sentiment analysis using different machine learning based models: A short review. 474–481.
- [36] SINGH, S., KUMAR, K., AND KUMAR, B. Sentiment analysis of twitter data using tf-idf and machine learning techniques. 252–255.
- [37] TAN, Y. Y., CHOW, C.-O., KANESAN, J., CHUAH, J. H., AND LIM, Y. Sentiment analysis and sarcasm detection using deep multi-task learning. *Wireless personal communications* 129, 3 (2023), 2213–2237.
- [38] TSAI, M.-F., AND HUANG, J.-Y. Sentiment analysis of pets using deep learning technologies in artificial intelligence of things system. *Soft Computing* 25, 21 (2021), 13741–13752.
- [39] WANG, Y., HUANG, G., LI, J., LI, H., ZHOU, Y., AND JIANG, H. Refined global word embeddings based on sentiment concept for sentiment analysis. *IEEE Access* 9 (2021), 37075–37085.
- [40] XU, L., AND SONG, Y. Comparison of text sentiment analysis based on traditional machine learning and deep learning methods. 692–695.
- [41] ZHANG, X., AND ZHENG, X. Comparison of text sentiment analysis based on machine learning. 230–233.